

Guía de estudio — Examen 1: Fundamentos

Aprendizaje Profundo y sus usos en Políticas Públicas · 2026

Esta guía tiene el **mismo formato que el examen** (Parte A: verdadero/falso con justificación; Parte B: desarrollo; Parte C: diagnóstico) y preguntas del mismo estilo, un poco más sencillas. Las respuestas orientativas están al final. Úsala así: resuelve todo **a mano y con tiempo** (40 minutos), y solo después compara. Si una respuesta te sorprende, regresa a la slide correspondiente antes de seguir.

El examen incluye al final un formulario con las distribuciones de probabilidad más comunes; todo lo demás debes saberlo. Aquí también lo incluimos para que practiques usándolo.

Parte A — Conceptos rápidos

Escribe V o F y justifica en una o dos líneas.

- A1. Gradient descent (no estocástico) con learning rate fijo siempre llega al mínimo global de la pérdida de una red neuronal.
 - A2. En regresión lineal, inicializar todos los parámetros en cero funciona sin problema.
 - A3. La binary cross-entropy es lo que se obtiene al asumir una distribución Bernoulli para y y conectar la red con una sigmoide.
 - A4. Aumentar el número de observaciones de entrenamiento reduce el sesgo del modelo.
 - A5. En SGD, la regularización L_2 equivale a multiplicar los pesos por $(1 - \eta\lambda)$ en cada actualización, y por eso se llama weight decay.
 - A6. En inferencia, BatchNorm normaliza usando la media y la varianza del mini-batch que se está evaluando.
 - A7. Una red ReLU superficial con un input y D unidades ocultas produce a lo más $D + 1$ regiones lineales.
 - A8. La inicialización He, $\sigma_{\Omega}^2 = 2/D_h$, está diseñada para redes con activación tanh.
 - A9. Corremos SGD con mini-batches de tamaño 50 sobre 1,000 observaciones durante 600 iteraciones. Eso equivale a 30 épocas.
 - A10. En el fenómeno de double descent, después del umbral de interpolación el error de test solo puede subir.
-

Parte B — Desarrollo

B1. Trazar una red a mano

Red superficial con activación ReLU, un input y dos unidades ocultas:

$$y = \phi_0 + \phi_1 h_1 + \phi_2 h_2, \quad h_1 = \text{ReLU}(x), \quad h_2 = \text{ReLU}(x - 2), \\ \phi_0 = 1, \quad \phi_1 = 2, \quad \phi_2 = -3.$$

- Calcula h_1, h_2 y y para $x = -1, x = 1$ y $x = 3$.
- ¿Dónde están las articulaciones? ¿Cuántas regiones lineales hay y cuál es la pendiente en cada una?
- Si la activación fuera la identidad, ¿qué función obtendrías?
- Si multiplicas los parámetros de h_2 por 4 (es decir, $h_2 = \text{ReLU}(4x - 8)$) y divides ϕ_2 entre 4, ¿cambia $y(x)$? ¿Por qué?

B2. Diseñar una función de pérdida

Un centro de atención telefónica quiere predecir el **tiempo de espera** $y > 0$ (en minutos) de cada llamada a partir de variables x como hora, día y número de operadores. Usará una red $f(x, \phi) \in \mathbb{R}$.

- Consulta el formulario. ¿Qué distribución propones para y y por qué no es adecuada la Normal?
- La distribución que elegiste tiene un parámetro con una restricción. ¿Cómo conectas $f(x_i, \phi)$ con ese parámetro?
- Escribe la negative log-likelihood y simplifícala en términos de $f(x_i, \phi)$ y y_i .
- Ahora el centro quiere predecir si la llamada **se abandona** antes de ser atendida (sí/no). ¿Qué cambia en cada paso de la receta?

B3. Backpropagation e inicialización

$$f_0 = \beta_0 + \omega_0 x, \quad h_1 = \text{ReLU}(f_0), \quad f_1 = \beta_1 + \omega_1 h_1, \quad \ell = (f_1 - y)^2.$$

Valores: $x = 1, y = 2, \beta_0 = 0.5, \omega_0 = 1, \beta_1 = -1, \omega_1 = 3$.

- Forward pass: f_0, h_1, f_1, ℓ .
- Backward pass: las cuatro parciales $\partial \ell / \partial \omega_1, \partial \ell / \partial \beta_1, \partial \ell / \partial \omega_0, \partial \ell / \partial \beta_0$. Escribe la cadena que usas.
- Si ω_0 fuera -1 (todo lo demás igual), ¿qué valdrían $\partial \ell / \partial \omega_0$ y $\partial \ell / \partial \beta_0$? ¿Cómo se llama esto?
- ¿Qué pasa si inicializamos todos los pesos y biases de una red profunda exactamente en cero? ¿Por qué en regresión lineal eso no es problema?

Parte C — Diagnóstico

Una dependencia entrena redes para clasificar **solicitudes ciudadanas** en 4 categorías a partir de 20 variables administrativas. Tiene 8,000 solicitudes etiquetadas, split 70/15/15. Después de 40 épocas (cross-entropy; el azar da 25 % de accuracy):

Exp	Modelo	LR	Train loss (ép. 40)	Val loss (ép. 40)	Val acc	Observaciones
1	1 capa, 8 unidades	0.001	0.90	0.92	60 %	Ambas pérdidas bajaron y se estancaron desde la época 15.
2	4 capas, 256 unidades	0.001	0.05	1.40	68 %	Val loss mínima (0.75, acc 74 %) en la época 10; después sube.
3	4 capas, 256 unidades	0.050	1.38	1.39	26 %	La pérdida oscila fuertemente desde el inicio y no baja.

- Diagnostica cada experimento: ¿sesgo, varianza u optimización? ¿Qué evidencia lo sostiene?
- Para el experimento 2, propón dos intervenciones y predice el efecto en train y val.
- El equipo dice: “probamos 15 combinaciones de hiperparámetros y reportamos la mejor accuracy en test: 74 %”. ¿Qué está mal y qué debieron hacer?
- Alguien propone “para el experimento 1, agreguen dropout 0.5”. ¿Tiene sentido? Justifica.

Formulario: distribuciones de probabilidad

Distribución	Soporte de y	Parámetros	$P(y)$ o $p(y)$	$E[y]$
Bernoulli	$\{0, 1\}$	$\lambda \in [0, 1]$	$\lambda^y(1 - \lambda)^{1-y}$	λ
Binomial	$\{0, \dots, m\}$	m fijo, $\lambda \in [0, 1]$	$\binom{m}{y} \lambda^y(1 - \lambda)^{m-y}$	$m\lambda$
Catórica	$\{1, \dots, K\}$	$\lambda_k \geq 0, \sum_k \lambda_k = 1$	λ_y	—
Geométrica	$\{0, 1, 2, \dots\}$	$\lambda \in (0, 1]$	$(1 - \lambda)^y \lambda$	$(1 - \lambda)/\lambda$
Poisson	$\{0, 1, 2, \dots\}$	$\lambda > 0$	$\frac{\lambda^y e^{-\lambda}}{y!}$	λ
Uniforme	$[a, b]$	$a < b$	$\frac{1}{b - a}$	$(a + b)/2$
Normal	$\mathbb{R}$	$\mu \in \mathbb{R}, \sigma^2 > 0$	$\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y - \mu)^2}{2\sigma^2}\right)$	μ
Laplace	$\mathbb{R}$	$\mu \in \mathbb{R}, b > 0$	$\frac{1}{2b} \exp\left(-\frac{ y - \mu }{b}\right)$	μ
Exponencial	$[0, \infty)$	$\lambda > 0$	$\lambda e^{-\lambda y}$	$1/\lambda$
Gamma	$(0, \infty)$	$\alpha > 0, \beta > 0$	$\frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}$	α/β
Beta	$[0, 1]$	$\alpha > 0, \beta > 0$	$\frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} y^{\alpha-1} (1 - y)^{\beta-1}$	$\frac{\alpha}{\alpha + \beta}$

Respuestas orientativas

No son las únicas redacciones válidas. Lo que se califica es el razonamiento.

Parte A

A1. **F.** La pérdida de una red no es convexa: hay mínimos locales, puntos silla y regiones planas; GD con lr fijo puede quedarse en cualquiera. La garantía de mínimo global es solo para funciones convexas.

A2. **V.** En regresión lineal no hay unidades ocultas que romper: el gradiente en cero no es nulo ni simétrico, y GD avanza. El problema de la inicialización en cero aparece con capas ocultas (ver B3d).

A3. **V.** $P(y|\lambda) = \lambda^y(1-\lambda)^{1-y}$ con $\lambda = \sigma(f(x, \phi))$; la NLL es $-\sum_i [y_i \log \lambda_i + (1-y_i) \log(1-\lambda_i)]$, que es la BCE.

A4. **F.** Más datos reduce la **varianza** (menos dependencia de la muestra particular). El sesgo depende de la familia de modelos: si la familia no puede representar la relación, más datos no lo arregla.

A5. **V.** $\nabla_w \frac{\lambda}{2} \|w\|^2 = \lambda w$; la actualización queda $w \leftarrow (1 - \eta\lambda)w - \eta \nabla_w L$: el peso se encoge un poco en cada paso.

A6. **F.** En inferencia usa estadísticas acumuladas (promedios móviles) durante el entrenamiento; si usara las del batch, la predicción de un ejemplo dependería de con quién le tocó ir en el batch.

A7. **V.** Cada unidad aporta una articulación donde su preactivación cruza cero; D articulaciones dividen la recta en a lo más $D + 1$ segmentos.

A8. **F.** He es para ReLU: como ReLU apaga la mitad de las unidades, $E[h^2] \approx \frac{1}{2}\sigma_f^2$ y se necesita $\sigma_\Omega^2 = 2/D_h$ para conservar la varianza. Para tanh/sigmoide se usa Xavier, $2/(D_{in} + D_{out})$.

A9. **V.** Una época son $1000/50 = 20$ iteraciones; $600/20 = 30$ épocas.

A10. **F.** Precisamente lo sorprendente del double descent es que, en el régimen sobreparametrizado, el error de test puede volver a **bajar** aunque el de entrenamiento ya sea cero.

Parte B

B1. a) $x = -1$: $h_1 = 0, h_2 = 0, y = 1$. $x = 1$: $h_1 = 1, h_2 = 0, y = 3$. $x = 3$: $h_1 = 3, h_2 = 1, y = 1 + 6 - 3 = 4$. b) Articulaciones en $x = 0$ y $x = 2$: tres regiones. Pendientes: $x < 0$: ninguna unidad activa, pendiente 0; $0 < x < 2$: solo h_1 , pendiente $\phi_1 \cdot 1 = 2$; $x > 2$: ambas, $2 - 3 = -1$. Comprobación: $y(0) = 1, y(2) = 5, y(3) = 4$. c) Con $a(z) = z, y = 1 + 2x - 3(x - 2) = 7 - x$: una recta, una sola región. Sin no linealidad la red colapsa a regresión lineal. d) No cambia: $\frac{\phi_2}{4} \text{ReLU}(4(x-2)) = \phi_2 \text{ReLU}(x-2)$ por homogeneidad no negativa de ReLU. Distintos parámetros, misma función.

B2. a) Exponencial (o Gamma): soporte $y > 0$; la Normal asigna probabilidad a tiempos negativos y supone simetría. b) Exponencial con tasa $\lambda > 0$: $\lambda_i = \exp(f(x_i, \phi))$ (o softplus). c) $L(\phi) = -\sum_i \log(\lambda_i e^{-\lambda_i y_i}) = \sum_i [\lambda_i y_i - \log \lambda_i] = \sum_i [e^{f(x_i, \phi)} y_i - f(x_i, \phi)]$. No hay constantes que eliminar en este caso. d) Bernoulli, sigmoide $\lambda_i = \sigma(f(x_i, \phi))$, binary cross-entropy.

B3. a) $f_0 = 1.5, h_1 = 1.5, f_1 = -1 + 4.5 = 3.5, \ell = (3.5 - 2)^2 = 2.25$. b) $\partial \ell / \partial f_1 = 2(3.5 - 2) = 3$. $\partial \ell / \partial \omega_1 = 3 \cdot h_1 = 4.5$; $\partial \ell / \partial \beta_1 = 3$; $\partial \ell / \partial h_1 = 3 \cdot \omega_1 = 9$; $\partial \ell / \partial f_0 = 9 \cdot \mathbf{1}[f_0 > 0] = 9$; $\partial \ell / \partial \omega_0 = 9 \cdot x = 9$; $\partial \ell / \partial \beta_0 = 9$. c) Con $\omega_0 = -1, f_0 = -0.5 < 0$: $h_1 = 0$ y $\mathbf{1}[f_0 > 0] = 0$, así que ambas parciales son 0. La unidad está “muerta” para ese ejemplo y no aprende. d) Simetría: todas las unidades de una capa reciben el mismo input, producen lo mismo y reciben el mismo gradiente;

permanecen idénticas y la red equivale a una unidad por capa. Con ReLU además los gradientes ocultos son cero. En regresión lineal no hay unidades que distinguir.

Parte C

- a) Exp 1: **sesgo** (subajuste): train y val altas y casi iguales, sin brecha; el modelo es demasiado pequeño. Exp 2: **varianza** (sobreajuste): train casi cero, val sube desde la época 10, brecha enorme. Exp 3: **optimización**: lr $50\times$ mayor, la pérdida oscila y nunca baja del nivel del azar ($\log 4 \approx 1.39$); es la misma arquitectura que 2, así que el problema es el paso, no el modelo.
- b) Early stopping en la época 10 (val baja a ~ 0.75 , acc $\sim 74\%$; train queda más alto); weight decay o dropout (train sube, val baja); reducir capacidad a un punto intermedio; más datos si se pueden conseguir. Cualquier dos con predicción coherente.
- c) Usar el test para elegir entre 15 configuraciones lo convierte en un conjunto de validación: el 74% es optimista. Elegir con validación y tocar el test **una sola vez** con la configuración final.
- d) No: el experimento 1 subajusta (sesgo alto). Dropout reduce varianza y aumenta sesgo, así que empeoraría train y probablemente val. Lo que necesita es más capacidad (más unidades o capas), no más regularización.