
PREGUNTAS ABIERTAS Y ÉTICA

Fernanda Sobrino

2026

¿Por qué funciona el aprendizaje profundo?

El gran misterio

- ▶ Sabemos que los modelos funcionan increíblemente bien en práctica.
- ▶ Pero nuestro entendimiento teórico sigue siendo limitado.
- ▶ Preguntas abiertas:
 - ▷ ¿Por qué entrenar redes tan grandes es posible?
 - ▷ ¿Por qué generalizan en datos nuevos y no solo memorizan?

Suposiciones al usar deep learning

1. Capacidad universal:

- ▷ Con suficientes neuronas, una red puede aproximar casi cualquier función.

2. Generalización:

- ▷ Lo aprendido en los datos de entrenamiento se traslada a datos nuevos.

▶ El problema:

- ▷ Entrenamiento no debería ser tan fácil (es NP-hard).
- ▷ Generalización no debería ocurrir tan bien (maldición de la dimensionalidad).

Entrenamiento: lo sorprendente

- ▶ Encontrar mínimos en funciones de pérdida no convexas es teóricamente muy difícil.
- ▶ Aun así:
 - ▷ No quedamos atrapados en mínimos locales malos ni en puntos silla.
 - ▷ Con sobreparametrización (más parámetros que datos), ¡el entrenamiento es incluso más estable!
- ▶ En práctica: ajustamos redes enormes de manera eficiente con SGD + trucos.
- ▶ *Paradoja*: lo que debería ser casi imposible en teoría, funciona rutinariamente bien en la práctica.

Generalización: otra paradoja

- ▶ Entrenar en pocos datos vs. espacio de entrada enorme:
 - ▷ cualquier dataset es muy chiquito frente a todas las combinaciones posibles
- ▶ Redes profundas = funciones muy complicadas con millones de parámetros.
- ▶ Solo unas pocas regiones del espacio se ven en entrenamiento... pero aún así generalizan bien.
- ▶ Más parámetros no empeoran la generalización → a veces la mejoran (double descent).

Factores que influyen en que el entrenamiento funcione

Factor	¿Qué aporta?	Limitaciones / Hallazgos
Datos	La función objetivo del mundo real suele ser relativamente simple; incluso con ruido o etiquetas permutadas, las redes pueden memorizar (Zhang et al., 2017).	Entrenan bien incluso con datos sin estructura → los datos no explican totalmente el éxito.
Regularización	Métodos como dropout, weight decay o batch norm suavizan la superficie de pérdida y pueden mejorar generalización.	No es estrictamente necesaria para entrenar; redes también aprenden datos aleatorios.

Factores que influyen en que el entrenamiento funcione

Factor	¿Qué aporta?	Limitaciones / Hallazgos
Optimización estocástica (SGD, Adam)	El ruido del muestreo ayuda a escapar de mínimos pobres y favorece soluciones planas que generalizan mejor.	Incluso métodos deterministas entrenan; los valles en la pérdida suelen ser amplios y buenos.
Sobreparametrización	Facilita el ajuste: más parámetros → más caminos hacia una buena solución. Explica el fenómeno de <i>double descent</i> .	Debería causar overfitting, pero en la práctica no siempre; la teoría aún es incompleta.

Factores que influyen en que el entrenamiento funcione

Factor	¿Qué aporta?	Limitaciones / Hallazgos
Funciones de activación	ReLU y variantes resolvieron problemas de gradientes con sigmoides/tanh; introducen no linealidad esencial.	Sin activaciones, la red sería lineal → incapaz de modelar funciones complejas.
Inicialización de pesos	Métodos como Xavier/He mantienen estable la varianza de activaciones y gradientes.	Inicialización deficiente puede colapsar el entrenamiento (explosión o desaparición de gradientes).

Factores que influyen en que el entrenamiento funcione

Factor	¿Qué aporta?	Limitaciones / Hallazgos
Profundidad	Capas profundas capturan jerarquías de representaciones: de patrones locales a abstracciones complejas.	Redes muy profundas eran inentrenables hasta la llegada de residuals y normalización.

Funciones de pérdida en deep learning

- ▶ Son **no convexas** y de muy alta dimensión.
- ▶ Aun así, los optimizadores encuentran soluciones buenas en la práctica.
- ▶ Pregunta central:
¿Por qué entrenar es posible si el problema es *teóricamente* difícil?

Propiedades de las funciones de pérdida

Propiedad	Qué significa	Implicaciones para DL
No convexidad	La pérdida es altamente no convexa, con muchos mínimos y puntos silla.	Teóricamente difícil de optimizar, pero en práctica hay muchos buenos caminos de descenso.
Abundancia de puntos silla	Los puntos silla son más comunes que los mínimos locales.	Los optimizadores estocásticos pueden escapar de ellos y seguir descendiendo.
Valles planos vs. afilados	Algunas soluciones están en regiones planas (robustas) y otras en picos estrechos.	Valles planos tienden a generalizar mejor; valles afilados sobreajustan.

Propiedades de las funciones de pérdida

Propiedad	Qué significa	Implicaciones para DL
Degeneración de soluciones	Muchas configuraciones distintas de parámetros logran la misma pérdida.	Explica la estabilidad del entrenamiento y la alta redundancia en redes grandes.
Conectividad entre mínimos	Los mínimos no están aislados, pueden estar conectados por caminos con pérdidas pequeñas.	La función* de la pérdida es “suave” → se pueden interpolar modelos sin empeorar mucho.
Sobrep parametrización	El número de parámetros excede lo necesario para ajustar los datos.	Aumenta la probabilidad de encontrar soluciones buenas y conectadas en la pérdida.

Intuición general de las funciones de pérdida

- ▶ Aunque la función de pérdida es altamente no convexa:
 - ▷ Hay muchos **caminos descendentes** hacia buenas soluciones.
 - ▷ Los mínimos relevantes están en **valles anchos y conectados**.
 - ▷ Esto hace que la optimización en deep learning sea sorprendentemente estable.

Factores de generalización en deep learning

- ▶ Una de las grandes preguntas:
 - ▷ ¿Por qué redes con millones de parámetros no colapsan en overfitting?
- ▶ Algunas claves:
 - ▷ Datos y distribución: qué tan bien reflejan el mundo real.
 - ▷ Capacidad del modelo: profundidad, número de neuronas, sobreparametrización.
 - ▷ Algoritmo de entrenamiento: ruido estocástico, tasa de aprendizaje, regularización implícita.
 - ▷ Geometría de la pérdida: soluciones planas vs. afiladas.

Factores de generalización en deep learning

Factor	Rol en la generalización	Limitaciones / Hallazgos
Cantidad y calidad de datos	Más datos reducen el sobreajuste y capturan mejor la distribución real.	Dataset siempre limitado; distribución de test puede diferir (<i>dataset shift</i>).
Arquitectura y capacidad	Redes profundas capturan jerarquías útiles; sobreparametrización sorprendentemente ayuda (<i>double descent</i>).	Capacidad excesiva debería sobreajustar, pero en la práctica no siempre.
Algoritmo de optimización	SGD introduce un “sesgo implícito”: prefiere soluciones planas que generalizan mejor.	No está garantizado teóricamente; depende de tasas de aprendizaje y batch size.

Factores de generalización en deep learning

Factor	Rol en la generalización	Limitaciones / Hallazgos
Regularización explícita	Técnicas como dropout, weight decay, data augmentation mejoran robustez.	No explican todo el fenómeno: modelos sin regularización también generalizan.
Paisaje de la pérdida	Soluciones en valles anchos son más estables y tienden a generalizar.	Difícil de medir directamente en grandes modelos.

Intuición de la generalización

- ▶ No hay un único “truco mágico”:
 - ▷ la generalización resulta de la interacción entre datos, modelo y optimización.
- ▶ SGD + sobreparametrización actúan como una forma de regularización implícita.
- ▶ En la práctica:
 - ▷ Los modelos encuentran soluciones planas y conectadas, no ajustes arbitrarios.
 - ▷ Esto explica por qué “más parámetros” a menudo significa mejor generalización.

¿Necesitamos tantos parámetros?

- ▶ Los LLMs y redes modernas tienen miles de millones de parámetros.
- ▶ Sorprendentemente: más parámetros → mejor generalización (double descent).
- ▶ Aun si el número de parámetros excede al de ejemplos de entrenamiento.
- ▶ Pregunta abierta:
 - ▷ ¿Es todo redundante o los parámetros extra juegan un rol esencial?

Ideas detrás de la sobreparametrización

Idea / hipótesis	Qué sugiere	Limitaciones / preguntas abiertas
Redundancia	Muchas neuronas o capas hacen lo mismo → parámetros innecesarios.	Entonces, ¿por qué al podar solo moderadamente baja el rendimiento?
Paisaje de pérdida más “amigable”	Más parámetros → más caminos hacia soluciones buenas → optimización más estable.	Explica el entrenamiento fácil, pero no toda la generalización.
Representaciones más ricas	Redes grandes aprenden múltiples subfunciones o especializaciones internas.	Difícil de interpretar; ¿qué tanto es aprovechado?
Pruning & Compresión	Modelos entrenados pueden reducirse (podado, distillation) sin perder mucho.	Pero necesitan entrenarse primero con exceso de parámetros.

Intuición sobreparametrización

- ▶ La sobreparametrización no es un bug, es una feature.
- ▶ Hace que el espacio de soluciones sea más suave y conectable.
- ▶ Muchos parámetros extras → mayor probabilidad de encontrar un valle ancho y robusto.
- ▶ Aun así, el misterio persiste:
 - ▷ ¿Cuántos parámetros son realmente necesarios para representar vs. para aprender?

¿Necesitamos redes tan profundas?

- ▶ En teoría, una red con una sola capa oculta suficientemente grande puede aproximar cualquier función continua (teorema de aproximación universal).
- ▶ Entonces, ¿por qué usar redes profundas en lugar de redes anchas?

Profundidad vs agregar muchas neuronas

Aspecto	Redes poco profundas (muy anchas)	Redes profundas
Capacidad teórica	Universal approximators si son lo bastante grandes.	También lo son, pero con menos neuronas totales.
Eficiencia de representación	Necesitan un número <i>exponencial</i> de neuronas para ciertas funciones.	Con profundidad logran la misma función con <i>mucho menos</i> .
Composición de funciones	Difícil de representar jerarquías o estructuras modulares.	Cada capa construye abstracciones progresivas (jerárquicas).
Práctica de entrenamiento	Redes anchas son costosas en memoria y parámetros.	Más fáciles de entrenar con técnicas modernas (residuals, normalización).
Generalización	Tienden a sobreajustar o memorizar más fácilmente.	Profundidad favorece reutilización y composicionalidad.

Intuición de la profundidad

- ▶ Composición de funciones simples $\rightarrow$ funciones complejas.
- ▶ Compactación de la representación: lo que en redes anchas requiere millones de neuronas, en redes profundas se logra con menos.
- ▶ Evidencia empírica: en práctica, aumentar profundidad (con cuidado) ha sido clave para grandes avances (ResNets, Transformers).

Entonces, ¿por qué funciona el aprendizaje profundo?

- ▶ El éxito del deep learning es sorprendente dado lo difícil que debería ser en teoría.
- ▶ Entrenamiento: funciona a pesar de funciones de pérdida no convexas y paisajes complicados.
- ▶ Generalización: las redes generalizan mejor de lo esperado, incluso con muchos más parámetros que datos.
- ▶ Factores clave: datos, sobreparametrización, SGD, activaciones, inicialización, regularización, profundidad.

Entonces, ¿por qué funciona el aprendizaje profundo?

- ▶ Pérdida: no convexa pero con valles anchos, conectados y buenos.
- ▶ Parámetros: muchos parecen redundantes, pero ayudan a entrenar y a encontrar mejores soluciones.
- ▶ Profundidad: esencial para eficiencia, composicionalidad y avances prácticos.
- ▶ RECUERDA: Aún no tenemos una teoría completa de por qué funciona el aprendizaje profundo
- ▶ Solo tenemos hints de cuales podrían ser las explicaciones detrás.

Ética en Aprendizaje profundo

Historia de la Ética en DL

- ▶ Desde AlexNet(2012) varios académicos intentaron enviar paneles de 'justicia' algorítmica y ética sin mucho éxito
- ▶ Fue hasta 2016 que ProPublica expuso el sesgo de COMPAS (modelo de predicción de reincidencia delictiva) que comenzó el interés en la ética/justicia detrás de estos modelos
- ▶ Desde 2019 se han creado al menos 84 documentos de distintas organizaciones con recomendaciones de política para el entrenamiento/arquitectura y uso de modelos de DL
- ▶ El problema dependen de la cooperación voluntaria y no vinculante de empresas privadas!!
- ▶ Por lo general las medidas éticas o de justicia son reactivas y no pro activas y se llevan a cabo cuando ya es muy evidente que el sistema/modelo esta sesgado o es dañino

De las recomendaciones a la regulación (2020-2026)

- ▶ La era de los “84 documentos voluntarios” terminó: ya hay regulación vinculante
- ▶ **EU AI Act (2024)**: el primer marco integral, basado en riesgo — prohibido / alto riesgo / riesgo limitado / mínimo
 - ▷ reglas para modelos de propósito general vigentes desde agosto 2025
 - ▷ las obligaciones de alto riesgo se **pospusieron a diciembre 2027**: la regulación se está adaptando en vivo al crecimiento de capacidades
- ▶ **NIST AI Risk Management Framework (EE.UU.)**: voluntario, pero se volvió el lenguaje común de gestión de riesgo (Govern / Map / Measure / Manage); **ISO 42001** lo vuelve certificable
- ▶ En 2026 NIST lanzó una iniciativa de estándares específicos para **agentes** — los marcos existentes no cubren del todo ese riesgo

México: la ley en camino

- ▶ México aún no tiene ley de IA en vigor
- ▶ Febrero 2026: iniciativa en el Senado para una Ley Nacional de IA con enfoque de riesgo (estilo EU AI Act) y una Comisión Nacional de IA (**CONAIA**)
- ▶ Contexto regional: Chile y Brasil avanzan marcos propios alineados con OCDE/UE
- ▶ Para ustedes es un proceso legislativo *vivo* que pueden seguir durante el semestre — y el tipo de proceso en el que gente con la formación de este curso debería estar en la mesa

Alineación de Problemas

- ▶ Idealmente quisiéramos que los valores de los sistemas de AI se alineen con los de la humanidad
- ▶ Pero esto es difícil porque:
 1. Es difícil definir nuestros valores de manera completa y correcta
 2. Es difícil codificar estos valores como objetivos de un modelo de IA
 3. Es difícil garantizar que el modelo aprenda a llevar a cabo estos objetivos.

Tipos de problemas de alineación en ML

► *outer alignment:*

- ▷ si no existe alineación entre nuestro objetivo y la función de pérdida
- ▷ la función de pérdida es un proxy para nuestros objetivos
- ▷ existen atajos que el sistema puede tomar para minimizar la función de pérdida sin lograr el objetivo
- ▷ por ejemplo un agente de RL que aprende a jugar ajedrez si lo premiamos

Tipos de problemas de alineación en ML

▶ *inner alignment:*

- ▷ garantizar que el comportamiento de un sistema de IA no se desvíe de los objetivos previstos, incluso si la función de pérdida está bien especificada
- ▷ esto puede pasar si por ejemplo los datos de entrenamiento no son representativos
- ▷ o si el entrenamiento es 'malo' y nunca encontramos el mínimo global
- ▷ tendremos una solución pero que no esta alineada con los objetivos

Tipos de problemas de alineación en ML

- ▶ Gabriel (2020) divide el problema de alineación en dos:
 1. *tecnico*: como programamos valores en los modelos, de manera que hagan lo que tiene que hacer
 2. *normativo*: cuales son los valores correctos.. no hay respuesta para esta parte

Sesgo y Equidad

- ▶ Recordemos en estadística el sesgo es la desviación de la norma
- ▶ Pero en AI esta desviación puede venir de factores *ilegítimos* por ejemplo:
 - ▷ la especificación del problema: los objetivos del modelo
 - ▷ datos: incompletos, no representativos, etc. Ojo incluso datos representativos podrían estar sesgados por prejuicios históricos
 - ▷ Modelado y validación: la métrica que usemos para medir fairness requiere un juicio de valor
 - ▷ Deployment: una vez afuera los modelos van a interactuar con otros algoritmos, sistemas, instituciones y pueden generar feedback loops

Definiciones formales de equidad

- ▶ “El modelo es justo” no es una afirmación única — hay definiciones formales *distintas*:
 - ▷ **Paridad demográfica**: la tasa de predicción positiva es igual entre grupos
 - ▷ **Igualdad de oportunidades / equalized odds**: las tasas de error (FPR, FNR) son iguales entre grupos
 - ▷ **Calibración por grupo**: un score de 0.7 significa 70 % de probabilidad real, en *todos* los grupos
- ▶ **Teorema de imposibilidad** (Kleinberg et al. 2016; Chouldechova 2017): si las tasas base difieren entre grupos, es *matemáticamente imposible* satisfacer las tres a la vez
- ▶ COMPAS es el ejemplo canónico: estaba calibrado por grupo, y *por eso mismo* tenía tasas de falsos positivos desiguales
- ▶ Elegir la definición es un juicio de valor — el teorema garantiza que no hay salida técnica que evite esa decisión

Mitigación de sesgo (panorama)

- ▶ **Pre-procesamiento:** re-pesar o re-muestrear los datos antes de entrenar
- ▶ **In-procesamiento:** agregar la restricción de equidad a la función de pérdida
- ▶ **Post-procesamiento:** ajustar umbrales de decisión por grupo sobre el modelo ya entrenado
- ▶ Ninguna elimina el problema de fondo (elegir *qué* igualar); todas cambian el trade-off equidad-exactitud
- ▶ Lo auditable: exigir las métricas por subgrupo *antes* del despliegue y monitorearlas después — como en los 5 mínimos

Artificial moral agency

- ▶ Muchas de las acciones de AI no tiene consecuencias morales (un RL que juegue Go, un clasificador de perros/gatos, etc)
- ▶ Pero muchas otras van a tener muchas decisiones morales por ejemplo: autos autónomos, drones que deciden por ellos mismos, robots al servicio de ancianos o enfermos

Transparencia y opacidad

- ▶ Un sistema computacional complejo es transparente si conocemos todos los detalles de su operación
- ▶ Un sistema es explicable si los humanos podemos entender como toma decisiones
- ▶ Si no tenemos al menos alguna de estas dos hay asimetría de la información entre el sistema de AI y los usuarios

Transparencia

► Hay tres niveles de transparencia:

1. Transparencia funcional: conocer el funcionamiento algorítmico del sistema
2. Transparencia estructural: sabemos como un programa ejecuta el algoritmo
3. Run transparency: sabemos como se ejecuto un programa en una instancia en particular, esto incluye el hardware, los datos de entrenamiento, los hyperparametros, etc

Transparencia: modelos cerrados vs de pesos abiertos

- ▶ El panorama se partió en dos desde 2023:
 - ▷ **Modelos cerrados** (API): solo transparencia funcional — no hay pesos, ni datos, ni código
 - ▷ **Modelos de pesos abiertos** (Llama, Mistral, Qwen, DeepSeek): pesos descargables — permiten auditoría, despliegue local y soberanía de datos, aunque los datos de entrenamiento suelen seguir opacos
- ▶ Para el sector público esta es una decisión de *procurement* de primer orden: qué nivel de transparencia exige el caso de uso

Explicabilidad e interpretabilidad

- ▶ Los sistemas pueden ser transparentes pero aun así puede que no sepamos ni entendamos porque deciden como deciden
- ▶ Herramientas **post-hoc** (explican una predicción sin abrir el modelo):
 - ▷ LIME: ajusta un modelo simple alrededor de la predicción
 - ▷ SHAP: atribuye la predicción a cada variable con una base de teoría de juegos
 - ▷ Saliencia / Grad-CAM: qué píxeles movieron la decisión de una CNN
- ▶ Advertencia: son *aproximaciones* — dos métodos pueden “explicar” la misma predicción de formas contradictorias

Interpretabilidad mecanicista (2023-2026)

- ▶ La agenda nueva: en vez de aproximar por fuera, **abrir el modelo** y buscar los cálculos internos
 - ▷ *probing*: ¿qué información está codificada en cada capa?
 - ▷ *sparse autoencoders*: descomponer las activaciones en “features” interpretables (conceptos)
 - ▷ *circuits*: rastrear qué componentes ejecutan qué sub-tarea
- ▶ Los laboratorios de frontera ya publican reportes de interpretabilidad/seguridad basados en estas técnicas — dejó de ser tema puramente académico
- ▶ Estado honesto a 2026: progreso real pero parcial — entendemos fragmentos, no el modelo completo
- ▶ Y un corolario importante para agentes: la cadena de razonamiento que el modelo *escribe* no siempre refleja el cálculo real (CoT no siempre es fiel)

Mal uso Intencional de la AI

- ▶ Face recognition: por ejemplo usar fotos obtenidas sin consentimiento para hacer frenología
- ▶ Militarización: cyber ataques, campañas de desinformación, drones autónomos
- ▶ Fraude: mails de phishing mas convincentes, deep fakes, chatbots que parecen humanos y solo quieren tu información
- ▶ Privacidad de datos: con el volumen de datos que se usan para entrenar DL aunque quitemos identificadores únicos puede ser fácil inferir estos identificadores

Otros problemas eticos y sociales de la AI

► Propiedad intelectual:

- ▷ muchos modelos de DL se entrenaron con contenido que tenia copyright sin pagar derechos
- ▷ ¿Podemos registrar la propiedad intelectual de un LLM?
- ▷ ¿Es moralmente aceptable (o incluso legal) hacer imágenes de Studio Ghibli sin pagarle a Miyazaki?

► Impacto ambiental:

- ▷ Entrenar un transformer con 213 millones de parámetros emite aproximadamente 284 toneladas de CO_2 al ambiente
- ▷ Esto es aprox el uso de 100 autos en una ciudad como LA por todo un año

Otros problemas eticos y sociales de la AI

- ▶ Concentración de poder (market power):
 - ▷ pocas empresas tienen los recursos para entrenar modelos gigantes.
- ▶ Mercado laboral:
 - ▷ automatización puede desplazar trabajos rutinarios de personas menos educadas o en partes del mundo mas pobres
 - ▷ mientras que los beneficios económicos de la AI se concentran en dueños de capital

El ideal de la ciencia libre de valores

- ▶ Ni los científicos ni los programadores existen en un vacío, sus valores se filtran a sus algoritmos/modelos/apps
- ▶ ML/DL no es objetiva solo porque los algoritmos son matemáticas
- ▶ Los valores del investigador/programador/desarrollador van a afectar su trabajo a través de:
 1. La elección del problema de investigación
 2. La recopilación de la evidencia
 3. Aceptar una hipótesis científica como respuesta a un problema.
 4. Aplicar los resultados de la investigación científica.

'Responsible AI' como problema de acción colectiva

- ▶ La investigación en IA responsable no puede resolverse solo a nivel individual:
 - ▷ Los beneficios de comportarse de manera ética (auditar, documentar, usar menos energía) son globales
 - ▷ Pero los costos son locales (tiempo, dinero, menor competitividad)
- ▶ Resultado: tragedia de los comunes
 - ▷ Cada actor (empresa/universidad/investigador) tiene incentivos a ignorar las buenas prácticas mientras los demás las cumplen

Necesidad de coordinación

- ▶ Para resolver problemas de acción colectiva, se requiere cooperación entre actores:
 - ▷ Normas compartidas.
 - ▷ Estándares de auditoría, seguridad y documentación.
 - ▷ Incentivos para respetarlos (ej. financiamiento, regulaciones, reputación).
- ▶ Analogía: como el cambio climático → no basta con que un país reduzca emisiones si los demás no lo hacen

Soluciones posibles

1. Instituciones internacionales:

- ▶ Crear organismos que coordinen investigación responsable y establezcan estándares.
- ▶ Ejemplo: similar a la IAEA en energía nuclear, pero para IA.

2. Regulación nacional

- ▶ Estados que imponen reglas mínimas sobre auditoría, privacidad, transparencia.

3. Auto-regulación colectiva:

- ▶ Consorcios de empresas y universidades que acuerdan “cartas éticas” vinculantes.

4. Presión pública y académica:

- ▶ Movimientos sociales, ONGs y científicos que exigen prácticas responsables.