
APRENDIZAJE PROFUNDO Y SUS USOS EN POLÍTICAS PÚBLICAS

Fernanda Sobrino

2026

Este curso:

Objetivos de este curso:

1. Entender las arquitecturas centrales del aprendizaje profundo (CNNs, Transformers, etc)
2. Implementar aprendizaje profundo de extremo a extremo usando Pytorch
3. Evaluar de manera critica modelos de aprendizaje profundo incluyendo desempeño, equidad y su impacto
4. Aplicar aprendizaje profundo a problemas reales (análisis de texto, análisis de imágenes, etc)
5. Diseñar sistemas robustos, transparentes y explicables más allá de cajas negras (no todo son LLMs, ni tienen la solución a todos nuestros problemas)

Prerequisitos: skills que ya deberian de tener

- ▶ Programación en python: clases, funciones, estructuras de datos, programación orientada a objetos, etc
- ▶ ML básico: funciones de pérdida, algoritmos de optimización, etc
- ▶ Flujos de trabajo de un producto de ciencia de datos

RoadMap del curso

- ▶ Semana 1-4: Fundamentos
 - ▷ Repaso de ML básico
 - ▷ Redes neuronales superficiales y profundas
 - ▷ Entrenamiento de redes neuronales
 - ▷ Regularización
- ▶ Semana 5-7: CNNs y RNNs — *Examen 1 (~semana 6); Hito 1 del proyecto: especificación (semana 7)*
- ▶ Semana 8-10: Transformers, LLMs y agentes
- ▶ Semana 11: ¿Por qué funciona el aprendizaje profundo?/ Fairness/Etica y preguntas abiertas — *Examen 2*
- ▶ Semana 12: Entrega final del proyecto de colaboración con IA

Evaluación

- ▶ 2 exámenes en clase de teoría, sin código, 40 minutos (30 % + 30 %)
 - ▷ Examen 1 (~semana 6): fundamentos; Examen 2 (~semana 11): CNNs, RNNs, Transformers y LLMs
 - ▷ Temarios detallados en la carpeta Exámenes/ del repo
- ▶ Proyecto de colaboración con IA (40 %): diriges a un agente de IA para ejecutar un experimento de DL; se califica tu especificación, tu verificación y tu interpretación — no el código (guía en el repo)
- ▶ No hay presentaciones de papers: la lista de papers clásicos queda como lectura opcional

Política de IA y tareas de práctica

- ▶ Las 8 tareas del curso son práctica no calificada: son la preparación directa para los exámenes
- ▶ El uso de LLMs está permitido en todo — pero los exámenes son en clase y a mano: úsenlos para entender, no para evitar entender/pensar
- ▶ En el proyecto es obligatorio entregar la transcripción completa de sus conversaciones con el LLM/agente

Papers clásicos (lectura opcional)

1. AlexNet — Krizhevsky, Sutskever & Hinton (2012)
2. ResNet (Deep Residual Learning) — He et al. (2015)
3. Batch Normalization — Ioffe & Szegedy (2015)
4. Transformers — “Attention is All You Need” — Vaswani et al. (2017)
5. BERT (Devlin et al., 2018)
6. Variational Autoencoders (VAE) — Kingma & Welling (2013)
7. GANs (Goodfellow et al., 2014)
8. Double Descent — Belkin et al. (2019) / Nakkiran et al. (2019)

Papers clásicos (lectura opcional)

- 9. Scaling Laws / Chinchilla — Hoffmann et al. (2022)
- 10. InstructGPT (RLHF) — Ouyang et al. (2022)
- 11. LoRA — Hu et al. (2021)
- 12. RAG — Lewis et al. (2020)
- 13. DeepSeek-R1 — DeepSeek-AI (2025)

Libros

- ▶ Prince, Understanding Deep Learning
- ▶ Xiao & Zhu, Foundations of Large Language Models (gratis, arXiv)
- ▶ Goodfellow et al., Deep Learning
- ▶ Zhang et al., Dive into Deep Learning
- ▶ Chollet, Deep Learning with Python

Papers de DL en políticas públicas:

- ▶ Medición de pobreza usando imágenes satelitales:
 - ▷ Jean et al. (2016) – Combining satellite imagery and machine learning to predict poverty (Science)
 - ▷ Yeh et al. (2020) – Using publicly available satellite imagery and deep learning to understand economic well-being in Africa (Nature Communications)
 - ▷ Huang, Hsiang & Gonzalez-Navarro (2021) – Using Satellite Imagery and Deep Learning to Evaluate the Impact of Anti-Poverty Programs (NBER Working Paper)
 - ▷ Rolf et al. (2021) – A generalizable and accessible approach to machine learning with global satellite imagery, MOSAIKS (Nature Communications)
 - ▷ Babenko et al. (2017) – Poverty Mapping Using Convolutional Neural Networks... (arXiv).

Papers de DL en políticas públicas:

► Análisis de textos legislativos

- ▷ Korn & Newman (2020) – A Deep Learning Model to Predict Congressional Roll Call Votes From Legislative Texts
- ▷ Chalkidis et al. (2019) – Large-Scale Multi-Label Text Classification on EU Legislation (arXiv).
- ▷ Wei et al. (2019) – Empirical Study of Deep Learning for Text Classification in Legal Document Review (arXiv).


Papers de DL en políticas públicas (era LLM):

- ▶ LLMs como herramienta de investigación y medición:
 - ▷ Gilardi, Alizadeh & Kubli (2023) – ChatGPT outperforms crowd workers for text-annotation tasks (PNAS)
 - ▷ Ziems et al. (2024) – Can Large Language Models Transform Computational Social Science? (Computational Linguistics)
 - ▷ Dell (2025) – Deep Learning for Economists (Journal of Economic Literature)


Introducción

Previously en ML 1: ¿Qué pasa si tenemos datos que se ven así?

- En ML1 solo llegamos hasta redes neuronales superficiales



¿Qué pasa si nuestros datos son imagenes/texto/grafos/videos?




¿Qué es el aprendizaje profundo?

- ▶ *Red neuronal profunda*: red neuronal con más de una capa intermedia (hidden layer) entre las capas de entrada y de salida
 - ▷ **Profundidad**: ≥ 2 capas ocultas/intermedias
 - ▷ **Parámetros aprendidos**: pesos y biases
 - ▷ **Activaciones**: ReLU, sigmoid, softmax...
- ▶ *Aprendizaje profundo*: cuando ajustamos una red neuronal profunda

¿Qué es el aprendizaje profundo?

- ▶ Actualmente son los modelos de ML más poderosa y los vemos en todos lados: traducción automática, creación de imágenes, vídeos, etc.
- ▶ Vamos a intentar entender el aprendizaje profundo sin derivar todos los algoritmos (si va a ha haber matemáticas pero no vamos a demostrar cosas) pero tampoco va a ser solo correr código en python (eso lo puede hacer el aprendizaje profundo solo)

Aprendizaje Profundo



Los 3 pilares del Deep Learning moderno

1. Datos masivos

- ▶ Internet y sensores generan billones de ejemplos diarios.

2. Cómputo acelerado

- ▶ GPUs permiten ejecutar en horas lo que antes tomaba meses.

3. Autodiferenciación

- ▶ Frameworks (PyTorch, TensorFlow) construyen grafos dinámicos y calculan gradientes por ti.

Hitos emblemáticos en Deep Learning

- ▶ **AlphaGo (2016)**: vence al campeón mundial de Go usando redes profundas + MCTS.
- ▶ **Neural Style Transfer (2015)**: mezcla contenido y estilo de imágenes con CNNs.
- ▶ **Transformers & GPT (2017–)**: revolucionan NLP con atención auto-regresiva.
- ▶ **Vision Transformers (2020)**: llevan la atención a visión por computador.
- ▶ **ChatGPT / RLHF (2022)**: los LLMs se vuelven asistentes de propósito general.
- ▶ **Modelos de razonamiento (2024)**: RL sobre problemas verificables; el modelo “piensa” más en los problemas difíciles.
- ▶ **Agentes (2025–)**: modelos que usan herramientas y completan tareas de varios pasos.

División de ML

- ▶ Recordemos que podemos dividir ML en tres: supervisado, no supervisado y aprendizaje por refuerzo.
- ▶ Actualmente todos los métodos de vanguardia para los tres tipos incluyen aprendizaje profundo
- ▶ Esta clase: supervisado y no supervisado

Pipeline típico de un proyecto de DL

1. **Definir modelo** (arquitectura, capas, activaciones)
2. **Preparar datos** (minibatches, normalización)
3. **Especificar pérdida & optimizador**
4. **Entrenar** (forward + backward)
5. **Evaluar & ajustar** (validación, regularización, hiperparámetros)
6. **Desplegar** (exportar modelo, APIs, monitorización)

Aprendizaje Supervisado


Aprendizaje Supervisado

- ▶ Definimos el mapeo entre input y output
- ▶ El algoritmo aprende usando los ejemplos de entrenamiento

Aprendizaje supervisado

1. Regresión
2. Regresión con grafos
3. Clasificación de texto
4. Clasificación de música
5. Clasificación de imágenes

Aprendizaje supervisado




Recordemos que hace un modelo supervisado:

- ▶ Toma inputs x y predice el output y
- ▶ Y queremos una $f()$ tal que $y = f(x)$
- ▶ El modelo encuentra parametros tales que $y = f(x, \phi)$
- ▶ Aprendemos estos parámetros utilizando el conjunto de entrenamiento $\{x_i, y_i\}$
- ▶ Recordemos la diferencia entre la predicción y el valor real lo cuantificamos utilizando una función de perdida, escalar que nos dice que tan bien esta ajustando el modelo a los datos de entrenamiento
- ▶ ¿Cómo entrenamos el modelo?

$$\hat{\phi} = \arg \min_{\phi} L(\phi)$$

Aprendizaje supervisado: ejemplo




Aprendizaje supervisado: ejemplo

- ▶ Queremos una ecuación que relacione la edad con la altura
- ▶ Podemos buscar sobre familias de posibles ecuaciones para encontrar alguna que ajuste bien los datos de entrenamiento
- ▶ Las redes neuronales profundas son una familia de ecuaciones muy flexibles (comparadas con otros algoritmos de ML que hemos visto antes)
- ▶ Ajustar una red neuronal profunda $\implies$ *aprendizaje profundo*

Aprendizaje profundo

- Problemas mas complejos que pueden resolver las RNP pero no algoritmos mas sencillos



Problemas mas complejos que pueden resolver las RNP pero no algoritmos mas sencillos

1. Segmentación de imágenes
2. Estimación de profundidad
3. Voz a texto
4. Traducción
5. Ponerle captions a una imagen
6. Generación de imágenes del texto

¿Qué tienen en común los últimos 3 ejemplos?

- ▶ Relaciones muy complejas entre el input y el output
- ▶ Puede que existan varias respuestas correctas
- ▶ Pero tanto los outputs como los inputs siguen ciertas reglas
- ▶ Ejemplo:
 - ▷ El lenguaje obedece reglas gramaticales
 - ▷ Las imágenes tienen que tener cierto sentido, hay combinaciones de píxeles que no significan nada


Aprendizaje No-Supervisado

- ▶ Para resolver estos problemas necesitamos alejarnos del aprendizaje supervisado
- ▶ La idea es aprender por ejemplo la estructura gramatical de los datos de entrenamiento sin dársele explícitamente al modelo
- ▶ Podemos usar muchos (millones) de datos sin labels para hacer esto
- ▶ Recordemos el aprendizaje no supervisado puede aprender de los datos sin labels cosas como:
 - ▷ clustering
 - ▷ encontrar outliers
 - ▷ generar nuevos ejemplos
 - ▷ llenar missing values

Aprendizaje No-Supervisado

- ▶ Aprender de nuevos datos sin labels
 - ▷ por ejemplo clustering
- ▶ Modelos generativos pueden crear nuevos ejemplo
 - ▷ por ejemplo generative adversarial networks
- ▶ PGMs (Probabilistic Generative models) aprenden la distribución de los datos:
 - ▷ variational autoencoders
 - ▷ normalizing flows
 - ▷ diffusion models

Aprendizaje No-Supervisado



Preview:

¿Por qué DL supera a métodos “shallow”?

- ▶ **Aprendizaje jerárquico de características:** las redes profundas extraen representaciones de muy bajo nivel (bordes, texturas) hasta alto nivel (formas, conceptos) de manera automática.
- ▶ **Menos ingeniería manual:** evitan el costo y el sesgo de diseñar features a mano (SIFT, TF-IDF, etc.).
- ▶ **Escalabilidad:** funcionan mejor cuanto más datos y capacidad de cómputo se disponen (¡grandes datasets + GPUs!).

Ventajas y retos del “feature learning”

► Ventajas:

- ▷ Adaptabilidad: el modelo descubre por sí mismo qué características son relevantes para la tarea.
- ▷ Transferibilidad: vectores aprendidos pueden reutilizarse para tareas nuevas (transfer learning).

► Retos:

- ▷ **Datos:** gran dependencia de volumen y calidad de datos etiquetados.
- ▷ **Opacidad:** “features” internos no siempre tienen interpretación clara para expertos en política pública.
- ▷ **Sobreajuste y sesgo:** sin regularización ni auditoría, el sistema puede aprender patrones no deseados.

Riesgos del DL

- ▶ Aunque compartimos muchos de los retos de los modelos “shallow”, en Deep Learning:
 - ▷ Es más difícil detectar cuándo algo falla
 - ▷ La enorme escalabilidad y complejidad pueden amplificar sesgos y errores
- 1. Datos Sesgados $\implies$ resultados injustos (si solo tengo imágenes de una parte de la ciudad o si tienen mejor calidad)
- 2. Interpretabilidad $\implies$ baja confianza institucional (decisiones ocultas en capas profundas no comprensibles para responsables de política)
- 3. Dependencia de cajas negras (LLMs/agentes) (asumir que el modelo “piensa” y delegar toda la responsabilidad en su output)
- 4. Costo ambiental: entrenamientos y despliegues masivos consumen grandes recursos energéticos.