

RNN

Fernanda Sobrino

2026

Introducción

Podemos hacer lo siguiente con las redes que aprendimos hasta ahora



Captioning Model

A happy dog is standing in the ocean

Podemos hacer lo siguiente con las redes que aprendimos hasta ahora




I'm eating an **apple** = Je mange une pomme



I'm eating an **orange** = Je mange une orange

Podemos hacer lo siguiente con las redes que aprendimos hasta ahora



¿Qué es una RNN?

- ▶ Recurrent neural networks
- ▶ Nos van a ayudar a completar tareas que tengan que ver con datos secuenciales
- ▶ Pueden aceptar tanto inputs como outputs que son secuencias
- ▶ Van a capturar las dinámicas de las secuencias usando conexiones recurrentes
- ▶ Casi todas las tareas que resuelven las RNNs tienen que ver con procesamiento del lenguaje natural

¿Qué tipo de tareas nos van a ayudar a resolver?

- ▶ Secuencias como outputs: image captioning, generar música, etc
- ▶ Secuencias como inputs: análisis de videos, clasificación de textos, clasificación de audio, etc
- ▶ Secuencias como inputs y outputs: traducción, chatbots, predicción de texto, etc

¿Cómo trabajamos con secuencias?

Secuencias de inputs

- ▶ Ahora nuestros inputs van a ser secuencias
- ▶ Lista ordenada de vectores de características $x_1, \dots, x_T$
- ▶ Donde x_t es el vector en el time step t y $t \in \mathbb{Z}^+$
- ▶ Por ejemplo nuestros inputs pueden ser:
 - ▷ una colección de documentos, cada documento es una secuencia con su propia longitud T_i
 - ▷ representación secuencial de las estancias de un paciente en el hospital, cada estancia es un conjunto de eventos y la longitud de la secuencia depende de cuanto duro la estancia en el hospital

Secuencias de inputs


- ▶ Cuando teníamos inputs individuales asumimos que los sampleamos los datos de manera independiente de una distribución $P(X)$
- ▶ Ahora vamos a asumir que toda la secuencia la sampleamos de manera independiente de una distribución de secuencias
- ▶ Pero no podemos asumir esto de los datos dentro de las secuencias ¿por qué?

Secuencias de outputs

- ▶ Depende de la tarea vamos a querer que la secuencia de inputs genere:
 - ▷ un solo input por ejemplo clasificar un texto y
 - ▷ una secuencia $(y_1, \dots, y_T)$ traducción

Modelos Autoregresivos

- ▶ Si tenemos datos como estos
- ▶ ¿Cómo calcularíamos el precio el siguiente día?



Modelos Autoregresivos

- ▶ Si no tenemos ninguna otra característica más que el pasado del precio podemos usarlo para predecir
- ▶ Nos interesa algo como: $P(x_t | x_{t-1}, \dots, x_1)$
- ▶ Estimar esta probabilidad no es tan fácil así que podríamos aspirar a algo como:

$$E[x_t | x_{t-1}, \dots, x_1]$$

- ▶ ¿Cómo? podemos usar una regresión lineal sobre los valores pasados un modelo autoregresivo
- ▶ El problema acá: el número de inputs aumenta junto con t
- ▶ Cada ejemplo en el tiempo va a tener un número distinto de características

Modelos Autoregresivos

- ▶ Existen varias maneras de restringir el número de features cuando t aumenta
- ▶ Opción 1: Usar una ventana de tamaño τ :
 - ▷ Todo lo mas alejado en el tiempo puede que no influya tanto
 - ▷ La cantidad de características ahora esta fija y es menor que t
 - ▷ $\Rightarrow$ el input es fijo y podemos usar casi cualquier modelo de ML

Modelos Autoregresivos

► Opción 2: Usar variables latentes

- ▷ Guardamos un resumen del pasado en una variable h_t
- ▷ Actualizamos esta h_t en cada momento del tiempo junto con x_t
- ▷ Ahora queremos $\hat{x}_t = P(x_t|h_t)$ y $h_t = g(h_{t-1}, x_{t-1})$
- ▷ Estos modelos se conocen como modelos latentes autoregresivos
- ▷ Nunca observamos h_t por eso son latentes

Estacionariedad

- ▶ Cuando tengamos datos secuenciales normalmente vamos a construir los ejemplos de entrenamiento sampleando ventanas de la secuencia de manera aleatoria
- ▶ Estamos asumiendo que la dinámica con la que se generan las nuevas observaciones dada la secuencia no cambia
- ▶ Este supuesto se conoce como estacionariedad

Estacionariedad

► En estadística hay dos definiciones de estacionariedad

1. Estricta: un proceso estocástico X_t es estrictamente estacionario si su distribución conjunta para $(X_{t_1}, X_{t_2}, \dots, X_{t_k})$ es la misma que para $(X_{t_1+h}, X_{t_2+h}, \dots, X_{t_k+h})$ para cualquier h
 - ▷ la probabilidad no cambia si nos desplazamos sobre la secuencia
2. Débil: normalmente la que se asume en DL
 - ▷ si la media es constante $E[X_t] = \mu \quad \forall t$
 - ▷ si la varianza es constante y finita $Var(X_t) = \sigma^2 \quad \forall t$
 - ▷ la autocovarianza solo depende de h : $\gamma(h) = Cov(X_t, X_{t+h})$

¿Por que nos importa la estacionariedad?

- ▶ Si los datos no son estacionarios entonces una RNN entrenada en una parte de la secuencia no va a funcionar en otras partes
- ▶ Existen varios trucos de pre-procesamiento para intentar hacer los datos 'mas' estacionarios
- ▶ Dependiendo de la tarea esto puede incluir diferencias, quitar tendencias, ajustar estacionalmente, etc

Modelos Secuenciales

- ▶ Un modelo secuencial va a ser aquel que estima la probabilidad conjunta de toda la secuencia
- ▶ Para texto normalmente estos modelos se llaman modelos del lenguaje
- ▶ Como casi todos estos modelos iniciaron en texto muchos libros/papers etc van a usar de manera intercambiable modelo de secuencia y modelo de lenguaje
- ▶ ¿Qué van a hacer los modelos del lenguaje?
 - ▷ Calcular la verosimilitud de una oración
 - ▷ Samplear secuencias verosímiles
 - ▷ Optimizar por la secuencia más probable

Modelos del Lenguaje

- ▶ Podemos escribir un modelo del lenguaje como un problema autoregresivo
- ▶ Descomponemos la distribución conjunta

$$P(x_1, \dots, x_T) = P(x_1) \prod_{t=2}^T P(x_t | x_{t-1}, \dots, x_1)$$

Modelos de Markov

- ▶ Una secuencia satisface la *condición de Markov*, el futuro es condicionalmente independiente del pasado dado la historia reciente
- ▶ Si $\tau = 1$ modelo de Markov de primer orden

$$P(x_1, \dots, x_T) = P(x_1) \prod_{t=2}^T P(x_t | x_{t-1})$$

- ▶ Si $\tau = k$ modelo de Markov de orden k

Orden

- ▶ ¿Por qué caracterizamos las secuencias de izquierda a derecha?
 - ▷ es el orden natural del texto en español (y en muchos otros idiomas)
 - ▷ factorizando el orden si tenemos la probabilidad de la secuencia hasta x_t fácilmente podemos calcular la que llega a x_{t+1}
 - ▷ los modelos van a ser mejores si predecimos la palabra que sigue a si intentamos predecir la que sigue después de otros 100/200 pasos

Modelos del Lenguaje

¿Cómo transformamos el texto en algo que la máquina pueda leer?

- ▶ Normalmente vamos a usar pre-procesamiento y esto se basa en 4 pasos
 1. Cargar el texto a la memoria
 2. Dividir los strings en tokens
 3. Construir un vocabulario y asociar cada elemento del vocabulario con un índice numérico
 4. Convertir el texto en secuencias

Tokens

- ▶ Unidades atómicas indivisibles de texto
- ▶ Cada *time step* t va a ser un token
- ▶ Un token puede ser una palabra o un caracter va a depender de lo que queramos contestar

Vocabulario

- ▶ Asocia cada token a un valor único en un índice
- ▶ Primero identificamos el conjunto de tokens únicos en nuestro corpus de entrenamiento
- ▶ Luego le asignamos un índice único a cada token
- ▶ Necesitamos un token <unk> que representa un token nunca antes visto!

Estadísticas del Lenguaje

- ▶ *stop words* palabras frecuentes en un idioma que no son particularmente descriptivas en español son palabras como *a, el, de, en, del,..*
- ▶ Algoritmos sencillos de NLP normalmente las eliminan, pero las redes no lo harán estas palabras dan contexto y pueden ayudarnos
- ▶ La frecuencia de las palabras en un texto sigue la Zipf's law que nos dice que la frecuencia de la i palabra más común esta dada por

$$n_i \propto \frac{1}{i^\alpha} \quad \equiv \quad \log n_i = -\alpha \log i + c$$

Estadísticas del Lenguaje

- ▶ Dada la Zipf's law no parece tan buena idea solo contar estadísticas de las palabras
- ▶ Vamos a sobre estimar las palabras poco frecuentes
- ▶ Si graficamos los bigramas (conjuntos de dos palabras) y los trigramas (conjuntos de tres palabras) ambas siguen la Zipf's law pero con α 's más pequeñas
- ▶ El número de n-grams únicos disminuye conforme aumentamos n
- ▶ Algunos n-grams casi nunca los vamos a ver

¿Cómo aprenden los modelos del lenguaje?

- ▶ Primero necesitamos convertir en tokens nuestro texto y aplicar probabilidades

$$P(\text{deep}, \text{learning}, \text{is}, \text{fun}) = P(\text{deep})P(\text{learning}|\text{deep})P(\text{is}|\text{deep}, \text{learning})P(\text{fun}|\text{deep}, \text{learning}, \text{is})$$

- ▶ ¿Cómo vamos a estimar estas probabilidades?
 - ▷ asumimos que tenemos un corpus enorme (todo el internet/Wikiped/..)
 - ▷ contamos
 - ▷ $\hat{P}(\text{learning}|\text{deep}) = \frac{n(\text{deep}, \text{learning})}{n(\text{deep})}$

¿Cómo aprenden los modelos del lenguaje?

- ▶ Hay algún problema con calcular así las probabilidades observadas de bigramas?
- ▶ Que pasa con parejas raras.. o con palabras que nunca ocurren juntas

Laplace smoothing

- ▶ La solución para no tener probabilidades de 0 cuando contamos n-grams
- ▶ Agregamos una pequeña constante
- ▶ Si n es el número de palabras en los datos de entrenamiento y m la cantidad de palabras únicas
 - ▷ $\hat{P}(x) = \frac{n(x) + \epsilon_1 / m}{n + \epsilon_1}$
 - ▷ $\hat{P}(x' | x) = \frac{n(x, x') + \epsilon_2 \hat{P}(x)}{n + \epsilon_2}$
 - ▷ $\hat{P}(x'' | x, x') = \frac{n(x, x', x'') + \epsilon_3 \hat{P}(x' | x)}{n(x, x') + \epsilon_3}$
- ▶ Donde las ϵ 's son hiperparámetros

Laplace smoothing

- ▶ Parece una buena solución pero...:
 - ▷ muchos n-grams casi no ocurren
 - ▷ tenemos que guardar todas estas sumas en algún lado
 - ▷ ignora el significado de las palabras
 - ▷ las secuencias muy largas por lo general son únicas un modelo como este es incapaz de generalizar

¿Cómo vamos a medir que tan bien lo hace un modelo del lenguaje?

- ▶ Idealmente queremos medir la verosimilitud de una secuencia
- ▶ Este número por lo general es difícil de entender y de calcular
- ▶ ¿Por qué?
 - ▷ las secuencias cortas son mas probables que las largas
 - ▷ queremos algo como un promedio para poder comparar entre secuencias largas y cortas

¿Cómo vamos a medir que tan bien lo hace un modelo del lenguaje?

- ▶ Un modelo del lenguaje mejor debería de ser capaz de predecir de manera mas precisa que token sigue
- ▶ Medir que tan cercana es la distribución de probabilidad del modelo comparada con los datos reales

¿Cómo vamos a medir que tan bien lo hace un modelo del lenguaje?

- ▶ Si normalizamos y sacamos el logaritmo de la verosimilitud regresamos a la cross-entropy

$$\frac{1}{n} \sum_{t=1}^n -\log P(x_t | x_{t-1}, \dots, x_1)$$

- ▶ Donde P es nuestro modelo del lenguaje y x_t es el token que observamos en el paso t
- ▶ Ahora podemos ver que tan bien lo hace el modelo independientemente de la longitud de la secuencia

Perplejidad

- ▶ Por razones históricas no vamos a usar la entropía cruzada sino una transformación de la misma llamada perplejidad

$$\exp\left(\frac{1}{n} \sum_{t=1}^n -\log P(x_t | x_{t-1}, \dots, x_1)\right)$$

- ▶ Si el modelo es perfecto, siempre le atina la probabilidad es 1 $\implies$ perplejidad de 1
- ▶ Si el modelo lo hace mal en todos los tokens la probabilidad es 0 $\implies$ la perplejidad $\rightarrow \infty$

Perplejidad

- ▶ Si el modelo predice una distribución uniforme sobre todos los tokens del vocabulario entonces la perplejidad va a ser igual al número de tokens únicos en el vocabulario
- ▶ Esto va a ser una buena cota superior para saber si nuestro modelo lo está haciendo al menos mejor que una uniforme en todo el vocabulario

¿Cómo creamos minibatches para el entrenamiento?

- ▶ Supongamos que tenemos una secuencia de T tokens
- ▶ Para poder entrenar el modelo necesitamos partir la secuencia en sub-secuencias
- ▶ Al principio de cada época vamos a introducir cierta aleatoriedad y vamos a tirar los primeros $d \sim U[0, n)$
- ▶ Partimos lo que queda de la secuencia en $m = \lfloor (T - d)/n \rfloor$
- ▶ Queremos sub-secuencias de tamaño n
- ▶ Cada una de estas subsecuencias las vamos a usar de input en el modelo
- ▶ Como queremos predecir el siguiente token las etiquetas van a ser las secuencias originales desplazadas un token

RNNs

Estado Oculto

- ▶ Vamos a usar como inspiración los modelos autoregresivos con variables latentes
- ▶ En vez de modelar la probabilidad del token x_t como dependiente de toda la secuencia previa
- ▶ La vamos a modelar como dependiente de una variable latente h_{t-1}

$$P(x_t | x_{t-1}, \dots, x_1) \approx P(x_t | h_{t-1})$$

- ▶ Donde h_{t-1} va a ser el estado oculto o *hidden state* y guarda información hasta el paso $t - 1$

Estado Oculto

- ▶ Podemos calcular el *hidden state* de la siguiente manera

$$h_t = f(x_t, h_{t-1})$$

- ▶ Ojo *hidden layer* $\neq$ *hidden state* en español deberíamos de tener menos problemas porque capa intermedia es muy distinto que estado oculto o latente
- ▶ RNNs son rede con hidden states!

Notación redes neuronales

- ▶ Capa intermedia $H = \phi(XW_{xh} + b_h)$
- ▶ Capa de salida: $O = HW_{hq} + b_q$ si es clasificación nos falta la softmax acá

Hidden State

- ▶ Si estamos en el time step t


$$H_t = \phi(X_t W_{xh} + H_{t-1} W_{hh} + b_h)$$

- ▶ La capa intermedia en t va a ser una ponderación entre los inputs en t y la capa intermedia del time step anterior $t - 1$
- ▶ El objetivo es que H_{t-1} nos ayude a conservar la historia parecido a nuestra variable latente autoregresiva
- ▶ El resultado de este tipo de capa intermedia va a ser nuestro *hidden state*

Hidden State

- ▶ Las capas que tengan esto se llaman capas recurrentes
- ▶ El output se va a ver igual que antes $O = HW_{hq} + b_q$
- ▶ Ojo: los parámetros no van a cambiar entre time steps, así que no van a aumentar los parámetros arbitrariamente con el número de pasos

Hidden State



Profundidad

- ▶ Las redes de las que hemos hablado hasta ahora son profundas
- ▶ Pero en lugar de muchas capas intermedias la longitud de la secuencia introduce una nueva profundidad
- ▶ Además de recorrer la red como antes de input-output pasando por capas intermedias ahora los inputs en el primer time step recorren la cadena de capas recurrentes T para influir el output
- ▶ Si hacemos propagación hacia atrás vamos a tener problemas parecidos que con redes de muchas capas
 - ▷ inestabilidad numérica $\implies$ que los gradientes explotan o desaparezcan
- ▶ ya conocemos un par de técnicas para evitar esto en capas intermedias ahora veremos como hacerlo en capas recurrentes

Recortar gradientes (gradient clipping)

- ▶ Nos va a ayudar a evitar gradientes que explotan
- ▶ Usando GD con una tasa de aprendizaje de η $x \leftarrow x - \eta g$ con g el gradiente
- ▶ Una función es continua de Lipschitz si cumple con lo siguiente

$$|f(x) - f(y)| \leq L\|x - y\|$$

- ▶ Si avanzamos un paso en el GD esto se ve así:

$$|f(x) - f(x - \eta g)| \leq L\eta\|g\|$$

Recortar gradientes (gradient clipping)

- ▶ Esto nos da una cota superior a cuanto va a cambiar la función objetivo cuando nos movemos
- ▶ Si esta cota superior no es muy grande puede ser bueno y malo
 - ▷ malo nos vamos a mover muy lento
 - ▷ bueno un paso no va a brincar demasiado
- ▶ Si $\|g\|$ es muy grande decimos que los gradientes explotan y un solo paso del GD puede movernos en dirección contraria del mínimo deshaciendo todo lo que habíamos avanzado
- ▶ La solución sin mover mucho la tasa de aprendizaje: recortar el gradiente

Recortar gradientes (gradient clipping)

$$g \leftarrow \min\left(1, \frac{\theta}{g}\right)g$$

- ▶ Esto asegura que la norma del gradiente nunca es mas grande que θ
- ▶ Y que el nuevo gradiente va en la dirección del original, no va a saltar el GD
- ▶ También reduce el efecto que cada minibatch puede tener en el entrenamiento
- ▶ Esto es un truco pero no sabemos analíticamente como afecta encontrar o no el mínimo
- ▶ Solo sabemos que se usa mucho con RNNs porque vuelve el entrenamiento menos inestable

Propagación hacia atrás a través del tiempo (secuencia)

- ▶ Vamos a necesitar desenrollar el grafo de la red paso a paso
- ▶ Esta RNN desenrollada es una red neuronal 'normal' con la propiedad de que se repiten algunos parámetros a lo largo de la red
- ▶ Así que a esta red desenrollada le podemos aplicar propagación hacia atrás como lo hacemos en cualquier otra red
- ▶ El problema viene de que la mayoría de las secuencias son muy largas

Gradientes

- ▶ *hidden state* $h_t = f(x_t, h_{t-1}, w_h)$
- ▶ output del time step t : $o_t = g(h_t, w_o)$
- ▶ Medimos el error como $L(x_1, \dots, x_T, y_1, \dots, y_T, w_h, w_o) = \frac{1}{T} \sum_{t=1}^T l(y_t, o_t)$
- ▶ Para propagación hacia atrás vamos a necesitar calcular

$$\begin{aligned} \frac{\partial L}{\partial w_h} &= \frac{1}{T} \sum_{t=1}^T \frac{\partial l(y_t, o_t)}{\partial w_h} \\ &= \frac{1}{T} \sum_{t=1}^T \frac{\partial l(y_t, o_t)}{\partial o_t} \frac{\partial g(h_t, w_o)}{\partial h_t} \frac{\partial h_t}{\partial w_h} \end{aligned}$$

- ▶ Los primeros dos términos de esto son fáciles de sacar el tercero no tanto

Gradientes

- $\frac{\partial h_t}{\partial w_h}$ se calcula de manera recurrente

$$\frac{\partial h_t}{\partial w_h} = \frac{\partial f(x_t, h_{t-1}, w_h)}{\partial w_h} + \frac{\partial f(x_t, h_{t-1}, w_h)}{\partial h_{t-1}} \frac{\partial h_{t-1}}{\partial w_h}$$

- ¿Cómo sacamos esto? vamos a usar un truco

Gradientes

- ▶ Tenemos tres secuencias $\{a_t\}, \{b_t\}, \{c_t\}$
- ▶ Donde $a_0 = 0$
- ▶ $a_t = b_t + c_t a_{t-1}$ entonces podemos escribir esto de la siguiente manera

$$a_t = b_t + \sum_{i=1}^{t-1} \left(\prod_{j=i+1}^t c_j \right) b_i$$

Gradientes

- ▶ Si nos damos cuenta estas secuencias nos sirven para reescribir nuestros gradientes
- ▶ $a_t = \frac{\partial h_t}{\partial w_h}$
- ▶ $b_t = \frac{\partial f(x_t, h_{t-1}, w_h)}{\partial w_h}$
- ▶ $c_t = \frac{\partial f(x_t, h_{t-1}, w_h)}{\partial h_{t-1}}$
- ▶ Y podemos escribirlo como:

$$\frac{\partial h_t}{\partial w_h} = \frac{\partial f(x_t, h_{t-1}, w_h)}{\partial w_h} + \sum_{i=1}^{t-1} \left(\prod_{j=i+1}^t \frac{\partial f(x_t, h_{j-1}, w_h)}{\partial h_{j-1}} \right) \frac{\partial f(x_t, h_{i-1}, w_h)}{\partial w_h}$$

- ▶ podemos calcular esta regla de la cadena pero si es muy larga va a ser un problema

¿Cómo calculamos el gradiente?

- ▶ **Completo:** se puede pero va a ser muy lento y puede explotar rápidamente
- ▶ **Truncado en el tiempo:**
 - ▷ Podemos truncar la suma después de τ pasos
 - ▷ Aproximación del verdadero gradiente
 - ▷ El modelo se centra en la influencia de corto plazo (igual y esto no es tan mala idea)

¿Cómo calculamos el gradiente?

► Truncado aleatoriamente:

- Usamos una secuencia ξ_t donde $P(\xi_t = 0) = 1 - \pi_t$ y $P(\xi_t = \pi_t^{-1}) = \pi_t$ y con $E[\xi_t] = 1$
- Entonces $z_t = \frac{\partial f(x_t, h_{t-1}, w_h)}{\partial w_h} + \xi_t \frac{\partial f(x_t, h_{t-1}, w_h)}{\partial h_{t-1}} \frac{\partial h_{t-1}}{\partial w_h}$
- Esta variable nueva sustituye a $\frac{\partial h_t}{\partial w_h}$ pero su esperanza es igual $E[z_t] = \frac{\partial h_t}{\partial w_h}$
- Si $\xi_t = 0$ el calculo recurrente termina en t
- Terminamos con una suma ponderada de secuencias de distintos tamaños

¿Cuál es mejor?

- ▶ **Truncado aleatoriamente:** divide el texto en segmentos de distintas longitudes
- ▶ **Truncado en el tiempo:** divide el texto en sub secuencias del mismo tamaño
- ▶ Aunque truncar aleatoriamente parece buena idea no lo hace mejor que solo truncar
- ▶ Regularizar con un tamaño de paso fijo va a tener efecto regularizador en la red y traerá varios de sus beneficios

Long Short-Term Memory (LSTM)

¿De dónde vienen?

- ▶ Las RNNs sencillas sufren de vanishing / exploding gradients cuando la secuencia es larga → la red no puede propagar señales a pasos temporales lejanos.
- ▶ LSTM introduce una célula de memoria con gates multiplicativos que controlan el flujo de información y permiten retener o borrar información durante largos intervalos.
- ▶ Especialmente útil cuando la tarea requiere recordar información a largo plazo (p. ej. dependencias a largo plazo en lenguaje)


Memory cell y Gates

- ▶ Cada paso temporal mantiene dos vectores:
 - ▷ *cell state* C_t información que va a pasar por muchos pasos temporales
 - ▷ *hidden state* h_t se usa para alimentar el siguiente paso temporal
- ▶ Los gates van a controlar que información se olvida, añade o transfiere
 - ▷ *Forget gate* f_t : decide que parte de C_{t-1} mantener
 - ▷ *Input gate* i_t : decide qué nueva información escribir en la célula
 - ▷ *Input node* $\tilde{C}_t$: candidato a nueva información
 - ▷ *Output gate* o_t : decide qué parte del estado de la célula produce la salida h_t

Memory cell y Gates

- ▶ *Forget gate:* $f_t = \sigma(x_t w_{xf} + h_{t-1} w_{hf} + b_f)$
- ▶ *Input gate:* $i_t = \sigma(x_t w_{xi} + h_{t-1} w_{hi} + b_i)$
- ▶ *Input node:* $\tilde{C}_t = \tanh(x_t w_{xc} + h_{t-1} w_{hc} + b_c)$
- ▶ *Output gate:* $o_t = \sigma(x_t w_{xo} + h_{t-1} w_{ho} + b_o)$

Memory cell y Gates



Memory cell y Gates

- ▶ donde $\odot$ es la multiplicación elemento por elemento

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$


- ▶ si $f_t = 1$ y $i_t = 0$ la célula de memoria va a permanecer constante
- ▶ estas dos gates son las que le dan flexibilidad al modelo
- ▶ y nos ayudan a resolver el problema de los gradientes que desaparecen
- ▶ la célula puede mantener información estable y solo modificar lo que sea necesario

Hidden state

$$h_t = o_t \odot \tanh(c_t)$$

- ▶ si $c_t \approx 1$ entonces la *memory cell* va a impactar en las capas que siguen
- ▶ si $c_t \approx 0$ evitamos que la *memory cell* afecte a otras capas en t
- ▶ las unidades de memoria pueden almacenar información a lo largo de varios intervalos de tiempo sin afectar a la red (si la salida es cerca a 0) y de repente encenderse (~ 1) y afectarla

Hidden state



Gated Recurrent Units (GRU)


GRU

- ▶ Versión optimizada de las células de memorias
- ▶ Se desempeña casi igual que LSTM pero es más rápida
- ▶ Vamos a reemplazar las 3 *gates* de LSTM por solo dos

Gates

- ▶ *reset gate*: cuanto del estado anterior queremos recordar, nos ayudan a capturar dependencias cortas
 - ▷ $r_t = \sigma(x_t w_{xr} + h_{t-1} w_{hr} + b_r)$
- ▶ *update gate*: cuanto del nuevo estado es solo una copia o parte del estado anterior, nos ayudan a capturar dependencias largas
 - ▷ $z_t = \sigma(x_t w_{xz} + h_{t-1} w_{hz} + b_z)$
- ▶ *candidate hidden state*: si $r_t \sim 0$ regresamos a una RNN normal
 - ▷ $\tilde{h}_t = \tanh(x_t w_{xh} + (r_t \odot h_{t-1}) w_{hh} + b_h)$
- ▶ *hidden state*: si $z_t \sim 1$ nos quedamos con el estado viejo e ignoramos lo que pueda aportar x_t
 - ▷ $h_t = z_t \odot h_{t-1} + (1 - z_t) \odot \tilde{h}_t$

GRU



RNNs bidireccionales

RNNs bidireccionales

- ▶ Hasta ahora solo hemos tomado el contexto de antes de la palabra
- ▶ Esto tiene sentido para algunas tareas pero para otras no tanto
- ▶ ¿Cómo podemos tomar el contexto de ambos lados? rnnns bidireccionales
- ▶ Por ejemplo para detección de voz o si queremos adivinar palabras faltantes de un texto (no necesariamente la que sigue)


RNNs bidireccionales

- ▶ Implementar dos capas de RNN unidireccionales juntas en direcciones contrarias en los mismos datos va a resolver esto
- ▶ Para la primera el primer input es x_1 y el último x_T
- ▶ Para la segunda el primero es x_T y el último x_1
- ▶ El resultado es la concatenación de los outputs de las dos RNNs

¿Cómo escribimos esto?

- ▶ $\vec{h}_t = \phi(x_t w_{xh}^{(f)} + \vec{h}_{t-1} w_{hh}^{(f)} + b_h^{(f)})$
- ▶ $\overleftarrow{h}_t = \phi(x_t w_{xh}^{(b)} + \overleftarrow{h}_{t-1} w_{hh}^{(b)} + b_h^{(b)})$
- ▶ Concatenamos estos dos *hidden states* $o_t = h_t w_{hq} + b_q$

¿Cómo se ven estas redes?



Secuencias y políticas públicas

Texto legislativo como datos

- ▶ Todo lo de hoy (tokenización, vocabulario, perplejidad, modelos de secuencia) es la maquinaria detrás del análisis de texto político y legal a escala:
 - ▷ Chalkidis et al. (2019): clasificación multi-etiqueta de ~57,000 leyes de la UE en ~4,300 categorías — imposible de mantener a mano
 - ▷ Korn & Newman (2020): predecir votos nominales en el Congreso desde el texto de las iniciativas
 - ▷ Wei et al. (2019): revisión de documentos legales con deep learning
- ▶ Otras secuencias de política pública: demanda de servicios (series de tiempo), trayectorias de pacientes, expedientes administrativos

De RNNs a Transformers

- ▶ Estos papers usan la generación anterior de herramientas (RNNs/LSTMs y primeros BERT)
- ▶ Hoy las mismas tareas se resuelven con Transformers — el tema de las próximas semanas
- ▶ Pero los conceptos de hoy no caducan: tokenización, OOV, perplejidad, y el diagnóstico de sobreajuste en pocos datos aplican igual
- ▶ Y las RNNs siguen vivas donde importa la eficiencia: secuencias largas con recursos limitados