
TRANSFORMERS

Fernanda Sobrino

2026

Arquitectura encoder-decoder

Motivación

- ▶ En problemas como traducir de un idioma a otro
- ▶ Los inputs y los outputs van a ser de distinto tamaño
- ▶ Las RNNs que vimos hasta ahora no necesariamente resuelven este problema
- ▶ Al menos no sin modificarlas
- ▶ Necesitamos algo como un encoder-decoder

Encoder-decoder

► Encoder:

- ▷ una RNN que procesa el input paso a paso
- ▷ cada token en la secuencia de entrada x_t se actualiza en el hidden state h_t
- ▷ después el último input token el hidden state h_T es considerado un *context vector*
- ▷ *context vector*: representación comprimida de toda la secuencia

Encoder-decoder


► Decoder:

- ▷ RNN que genera la secuencia de salida paso a paso
- ▷ Empieza con el *context vector* que le pasó el encoder + un token para empezar la secuencia de salida
- ▷ En cada paso predice que token y_t sigue condicionado al hidden state del paso anterior y al token generado antes
- ▷ Continúa hasta que genera un token de fin de secuencia

Intuitivamente

- ▶ Encoder: lee la secuencia y comprime toda su información en un vector de tamaño fijo, el *context vector*
- ▶ Decoder: escribe la secuencia de salida basada en el *context vector*
- ▶ Esto va a funcionar más o menos bien pero tiene el problema de que vamos a aplastar toda la secuencia en un solo vector de tamaño fijo
- ▶ Si las secuencias son muy largas vamos a perder información
- ▶ Tratamos el *context vector* como un estadístico suficiente de la señal de todo el input

Encoder-Decoder



Atención

¿Por qué queremos algo más que RNNs?

- ▶ Secuenciales: son computacionalmente muy costosas
- ▶ Gradientes que desaparecen: si tenemos secuencias muy largas no hay muchas maneras de resolver esto
- ▶ Con secuencias muy largas vamos a perder información :(

Atención

- ▶ El *context vector* del encoder-decoder de RNN va a perder información
- ▶ Queremos que el decoder pueda mirar todos los estados ocultos del encoder
- ▶ Para que en cada paso pueda enfocarse en la parte relevante de la secuencia de entrada
- ▶ Para lograrlo necesitamos un mecanismo que compare lo que el decoder “quiere” generar con la información almacenada en el encoder

¿Cómo logramos esto? Queries, Keys y Values

- ▶ Inspiración: mecanismos de búsqueda y recuperación de información
 - ▷ Query q : lo que estamos buscando $\rightarrow$ estado actual del decoder
 - ▷ Keys k : representaciones de cada token del encoder (las “etiquetas”)
 - ▷ Values v : información contenida en esos tokens (los mismos estados del encoder)
- ▶ La atención compara la Query con todas las Keys, y obtiene un peso de relevancia para cada Value
- ▶ De esta forma, el decoder recibe un vector de contexto dinámico que resalta justo la parte de la secuencia que necesita

Intuición de q, k y v

- ▶ Piensa en una biblioteca:
 - ▷ Query: tu pregunta (“quiero información sobre gatos”)
 - ▷ Keys: los temas/indices de cada libro
 - ▷ Values: el contenido de los libros
- ▶ El sistema busca qué Keys se parecen más a la query y devuelve los values más relevantes

¿Qué beneficios tiene pensar en términos de q, k y v ?

- ▶ Podemos designar queries q que operen en pares (k, v) de tal manera que sean válidas independientemente del tamaño de los datos
- ▶ La misma query puede recibir diferentes respuestas, según el contenido de la base de datos.
- ▶ El código detrás para buscar en un espacio muy grande puede ser bastante simple
- ▶ No es necesario comprimir ni simplificar la base de datos para que las operaciones sean efectivas

Atención

- ▶ Si tenemos una base de datos $D = \{(k_1, v_1), \dots, (k_m, v_m)\}$ de m tuplas de keys y values
- ▶ Y un vector de queries q
- ▶ Podemos definir la atención sobre D como:

$$Attention(q, D) = \sum_{i=1}^m \alpha(q, k_i) v_i$$

- ▶ Donde $\alpha(q, k_i)$ son los pesos de atención
- ▶ Y esta operación se conoce como *attention pooling*

¿Qué nos dice esta función de atención?

- ▶ Si los pesos $\alpha(q, k_i) > 0$ el resultado vive en un cono convexo de los valores de v_i
- ▶ Los pesos van a formar una combinación convexa si $\sum_i \alpha(q, k_i) = 1$ y $\alpha(q, k_i) \geq 0$, normalmente vamos a asumir esto
- ▶ Si solo un $\alpha(q, k_i) = 1$ y los demás son cero solo prestamos atención a un valor
- ▶ Si $\alpha(q, k_i) = \frac{1}{m}$ vamos a tener average pooling, le prestamos la misma atención a todos los tokens


¿Qué nos dice esta función de atención?

- ▶ Por lo general vamos a usar como mecanismo de atención

$$\alpha(q, k_i) = \frac{e^{a(q, k_i)}}{\sum_j e^{a(q, k_j)}}$$


- ▶ Esta función tiene varias propiedades que nos van a ayudar en DL:
 - ▷ los pesos suman 1
 - ▷ son no negativos
 - ▷ es diferenciable
 - ▷ el gradiente nunca desaparece
- ▶ El mecanismo de atención es una operación relativamente sencilla a pesar de las dimensiones de las matrices

¿Qué nos dice esta función de atención?



Distintas funciones de atención

Ejemplo de attention pooling



Atención producto punto

$$a(q, k_i) = \frac{q^T k_i}{\sqrt{d}}$$

- ▶ Donde d es la dimensión de q y k_i
- ▶ Esta es nuestra función a pero necesitamos α

$$\alpha(q, k_i) = \text{softmax}(a) = \frac{e^{q^T k_i / \sqrt{d}}}{\sum_j e^{q^T k_j / \sqrt{d}}}$$

Atención producto punto

- ▶ Requiere que tanto q como k_i sean de la misma dimensión d
- ▶ Si tenemos queries y keys en distintos espacios podríamos solucionar el problema con una matriz M
- ▶ Esta matriz M es una transformación lineal que proyecta uno de los espacios para que sean compatibles en dimensiones
- ▶ En la practica no vamos a hacer esto

Atención aditiva

- ▶ Esta va a funcionar sin importar si q y k_i tienen la misma dimensión
- ▶ Como es aditiva puede ser más rápida y eficiente computacionalmente que otras atenciones

$$a(q, k) = w_v^T \tanh(W_q q + W_k k)$$

- ▶ Donde w_v , W_q y W_k son parametros que va a aprender el modelo
- ▶ Esto lo metemos en una softmax

Ventajas de la atención aditiva

- ▶ Flexibilidad dimensional: no requiere que queries y keys estén en el mismo espacio de dimensión
- ▶ Mayor expresividad: la combinación no lineal con $\tanh$ permite capturar relaciones más complejas entre q y k
- ▶ Estabilidad numérica: menos sensible a valores muy grandes que pueden ocurrir en el producto punto
- ▶ Buen desempeño en práctica: funciona bien cuando las dimensiones de q y k son muy distintas o pequeñas
- ▶ Forma original de atención propuesta en Bahdanau et al. (2014) para traducción automática

Mecanismo de atención

Introducción

- ▶ La solución al problema de los encoder-decoders de RNN es la atención
- ▶ Bahdanau et al. (2014) propusieron:
 - ▷ Para predecir un token, no todos los tokens de entrada son igualmente relevantes
 - ▷ El modelo aprende a poner más peso (atención) en las partes relevantes de la secuencia de entrada para la predicción actual
 - ▷ Este mecanismo actualiza dinámicamente la representación usada por el decoder antes de generar el siguiente token
- ▶ Aunque la idea es sencilla, revolucionó el deep learning → es la base de los modelos modernos de NLP y LLMs

Modelo

- ▶ La idea clave es que la *context variable* c no está fija como en el encoder-decoder clásico, sino que se actualiza dinámicamente en cada paso
- ▶ En el paso t' del decoder:


$$c_{t'} = \sum_{t=1}^T \alpha(s_{t'-1}, h_t) h_t$$

- ▶ Donde:
 - ▷ $s_{t'-1}$ = estado oculto del decoder en el paso anterior (query)
 - ▷ h_t = estado oculto del encoder en el tiempo t (key y value)
 - ▷ $\alpha(s_{t'-1}, h_t)$ = peso de atención que indica la relevancia de h_t para la predicción en t'

Intuición

- ▶ En lugar de un solo *context vector* fijo, ahora tenemos un contexto adaptado a cada paso de generación
- ▶ Esto permite que el decoder consulte directamente las partes relevantes del input en cada momento
- ▶ Ejemplo: al traducir “The cat sat on the mat”, al predecir “gato” el modelo pondrá más atención en el hidden state correspondiente a “cat”

¿Cómo se ve?



Pasos del mecanismo de atención

1. Queries (Q): vector que representa lo que busca el decoder en este paso.
2. Keys (K): representaciones de cada token de entrada.
3. Values (V): la información asociada a cada token de entrada.
4. Cálculo de scores: se mide la similitud entre la query y cada key, generando $a(q, k_i)$.
5. Normalización (softmax): los scores se convierten en pesos $\alpha(q, k_i)$ que suman 1.
6. Combinación ponderada: el contexto c se obtiene como la suma de los values, cada uno multiplicado por su peso de atención.

Multi-Head Attention

Motivación

- ▶ Una sola atención puede ser limitada: solo aprende un tipo de relación entre tokens.
- ▶ Queremos que el modelo pueda poner atención en paralelo a distintos aspectos de la secuencia:
 - ▷ Relaciones de largo alcance
 - ▷ Relaciones locales
 - ▷ Diferentes tipos de dependencias semánticas o sintácticas

Idea clave

- ▶ En vez de calcular una única atención, calculamos varias en paralelo.
- ▶ Cada atención es una cabeza (head).
- ▶ Cada cabeza tiene sus propias matrices de proyección W^Q, W^K, W^V .
- ▶ El resultado final concatena todas las cabezas y se proyecta de vuelta al espacio original.

Definición:

- ▶ Si tenemos h cabezas de atención
- ▶ Cada cabeza de atención la calculamos como

$$h_i = f(W_i^{(q)}q, W_i^{(k)}k, W_i^{(v)}v)$$

- ▶ La multi-head se compone:

$$[h_1, \dots, h_h]W_o$$

- ▶ Donde vamos a aprender todas las matrices W_i^Q , W_i^K , W_i^V y W^O que mezcla las salidas de todas las cabezas

¿Por qué querriamos usar esto?


► Intuición:

- ▷ Cada cabeza aprende a mirar la secuencia de una manera diferente.
- ▷ Ejemplo: una cabeza puede enfocarse en concordancia sujeto-verbo, otra en dependencias largas, otra en entidades.
- ▷ Juntas, proveen una representación más rica y robusta.

► Ventajas:

- ▷ Permite capturar múltiples relaciones en paralelo
- ▷ Mejora la capacidad del modelo para aprender estructuras complejas del lenguaje.
- ▷ Hace al modelo más expresivo sin incrementar demasiado la complejidad.

¿Cómo se ve esto?



Comparación Self-Attention vs Multi-Head Attention

Aspecto	Self-Attention	Multi-Head Attention
Definición	Cada token atiende a todos los demás en una sola matriz de atención	Ejecuta varias auto-atenciones en paralelo con diferentes proyecciones
Perspectiva	Una sola “vista” de la secuencia	Varias “vistas” simultáneas que capturan distintos patrones
Capacidad expresiva	Limitada: puede pasar por alto ciertas relaciones	Más rica: cada cabeza puede enfocarse en dependencias diferentes
Ejemplo	Una lupa única para leer la secuencia	Muchas lupas que enfocan en diferentes detalles a la vez
Uso práctico	Base del mecanismo de atención	Núcleo de los Transformers modernos

Self-Attention y Positional Encoding




Self-Attention en Transformers

- ▶ En los Transformers, cada token se representa como un embedding.
- ▶ Self-Attention: cada token pone atención a todos los demás tokens de la misma secuencia.
- ▶ Esto permite que cada representación incorpore contexto global desde el inicio.
- ▶ Diferencia clave con la atención encoder-decoder:
 - ▷ Encoder-decoder attention: conecta entre secuencias distintas (input $\rightarrow$ output).
 - ▷ Self-attention: conecta dentro de la misma secuencia (input $\rightarrow$ input).

Limitación de Self-Attention

- ▶ La operación de self-attention es invariante al orden de los tokens.
- ▶ Ejemplo: “el gato come pescado” vs “pescado come el gato” → self-attention sin más no distingue el orden.
- ▶ Necesitamos introducir información sobre la posición de los tokens en la secuencia.

¿Cómo se ve esto?



Positional Encoding

- ▶ Solución: añadir codificación posicional a cada embedding antes de aplicar self-attention.
- ▶ Dos enfoques:
 - ▷ Sinusoidal (fija): usa senos y cosenos con diferentes frecuencias.
 - ▷ Aprendida: posiciones como vectores entrenables
- ▶ Fórmulas sinusoidales:
 - ▷ $PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d}}\right)$
 - ▷ $PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d}}\right)$
- ▶ Permite que el modelo capture orden y distancia relativa entre tokens

Intuición de Positional Encoding

- ▶ Cada posición se representa como un patrón de ondas senoidales.
- ▶ Propiedades:
 - ▷ Diferentes dimensiones codifican distintas escalas de posición.
 - ▷ Tokens cercanos tienen codificaciones similares.
 - ▷ Funciona para secuencias más largas que las vistas en entrenamiento.
- ▶ Intuición: similar a dar coordenadas a cada palabra en la secuencia.

Comparación de codificaciones posicionales

Aspecto	Sinusoidal (fija)	Aprendida
Definición	Vectores generados con senos y cosenos de distintas frecuencias	Vectores de posición entrenables como embeddings
Generalización	Funciona para secuencias más largas que las vistas en entrenamiento	Limitada a longitudes de secuencia vistas en entrenamiento
Interpretabilidad	Fácil de visualizar → posiciones cercanas tienen representaciones similares	Más difícil de interpretar
Parámetros adicionales	No añade parámetros → eficiente	Añade parámetros proporcionales a la longitud máxima de secuencia
Uso práctico	Se usa en el Transformer original (Vaswani et al., 2017)	Ampliamente usada en modelos modernos (BERT, GPT, etc.)

Transformers

Idea general

- ▶ Propuesto en “Attention is All You Need” (Vaswani et al., 2017).
- ▶ Reemplaza la recurrencia y convoluciones con solo mecanismos de atención.
- ▶ Compuesto por:
 - ▷ Un encoder (procesa la secuencia de entrada).
 - ▷ Un decoder (genera la secuencia de salida).
- ▶ Totalmente paralelizable, eficiente y capaz de modelar dependencias largas.

Bloques del Transformer

► Encoder:

- ▷ Embeddings + codificación posicional.
- ▷ Varias capas de:
 1. Multi-head self-attention.
 2. Red neuronal feed-forward posición a posición.
 3. Normalización y conexiones residuales.

► Decoder:

- ▷ Similar al encoder, pero incluye:
 - Masked self-attention (para no mirar tokens futuros).
 - Atención encoder-decoder (usa salidas del encoder).

Encoder: detalles

- ▶ Cada capa del encoder contiene:
 1. Multi-head self-attention: cada token atiende a todos los demás tokens de entrada.
 2. Feed-forward network: dos capas lineales con activación intermedia (ReLU o GELU).
 3. Residual + LayerNorm: ayuda al entrenamiento estable.
- ▶ Replicado N veces (por ejemplo, $N = 6$ en el Transformer original).

Decoder: detalles

- ▶ Cada capa del decoder contiene:
 1. Masked multi-head self-attention: cada posición solo atiende a posiciones previas (autoregresivo).
 2. Multi-head encoder-decoder attention: conecta las representaciones del encoder con el decoder.
 3. Feed-forward network.
 4. Residual + LayerNorm.
- ▶ También replicado N veces


Normalización y Residuales

- ▶ Residual connections: $x + \text{Sublayer}(x)$.
- ▶ Layer Normalization: aplicada después de cada subcapa.
- ▶ Beneficios:
 - ▷ Evita que los gradientes desaparezcan/exploten.
 - ▷ Facilita entrenar arquitecturas muy profundas.

Embeddings y salida

- ▶ Tokens $\rightarrow$ vectores mediante word embeddings.
- ▶ Se suman con la codificación posicional antes de entrar al encoder/decoder.
- ▶ Al final, el decoder usa una capa lineal + softmax para predecir el próximo token.

Transformer



Flujo completo

1. Input embeddings + positional encoding $\rightarrow$ encoder.
2. Encoder produce representaciones contextuales.
3. Decoder recibe embeddings + positional encoding y va generando la secuencia:
 - ▷ Self-attention mira solo el pasado.
 - ▷ Cross-attention consulta al encoder.
4. Capa final: predicción del siguiente token.

Transformers para NLP


Pipeline general

- ▶ Texto → tokenización → IDs → embeddings (token + posición [+ segmento]) → Transformer → cabeza de tarea → pérdida/decodificación.
- ▶ Una estructura básica simple sirve para muchas tareas cambiando solo la cabeza o el esquema de decodificación.
- ▶ Dos fases típicas: preentrenamiento (auto-supervisado en corpora grandes) → fine-tuning (tarea específica).

Tokenización

- ▶ Por qué no caracteres ni palabras completas:
 - ▷ Palabras → vocab enorme y OOV(out-of-vocabulary); caracteres → secuencias largas y menos semántica.
- ▶ Subpalabras (BPE/WordPiece/Unigram): compromisos robustos OOV ↔ longitud de secuencia.
- ▶ Detalles prácticos:
 - ▷ Tokens especiales: [CLS], [SEP], [PAD], <s>, </s>, etc.
 - ▷ Padding/Truncation a `max_len` y máscara de atención para ignorar padding.
 - ▷ Casing, normalización, y manejo de signos.

Tokenización



Tokenización

- ▶ ¿Qué hay en la imagen?
- ▶ Vemos la frecuencia de los tokens en el párrafo
- ▶ En cada iteración busca por los tokens que aparecen mas juntos y los concatena, creando menos tokens
- ▶ Después de muchas iteraciones los tokens son una combinación de letras, pedazos de palabras y algunas palabras muy usadas.
- ▶ Si seguimos haciendo esto terminamos con palabras completas

¿Qué es OOV?

- ▶ Out-Of-Vocabulary
- ▶ En NLP tradicional, los modelos trabajan con un vocabulario fijo de palabras o subpalabras.
- ▶ Cuando aparece una palabra en el texto que no estaba en ese vocabulario durante el entrenamiento, se considera OOV.
- ▶ Problemas:
 - ▷ Los modelos no saben cómo representar esa palabra.
 - ▷ Antes se usaban tokens especiales como <unk> (unknown) → pero esto pierde información.
- ▶ Solución: algo como subword tokenization

Embeddings que entran al modelo

- ▶ Token embeddings + positional encoding (fijo sinusoidal o aprendido).
- ▶ Segment/Type embeddings (BERT) para pares de secuencias (ej. premisa/hipótesis).
- ▶ Input final = suma (o concat) de estos componentes → pasa a la primera capa del Transformer.


Máscaras de atención (Attention Masks)

- ▶ Padding mask: evita que [PAD] afecte la atención.
- ▶ Causal mask (autoregresivo): cada posición solo atiende a $\leq$ su índice (no mira el futuro).
- ▶ Mask de segmentos (opcional): restringe atención entre partes (p. ej., en tareas de pares).


Objetivos de preentrenamiento (pretraining)


- ▶ Encoder-only (BERT):
 - ▷ MLM (Masked Language Modeling): enmascara ~15 % de tokens y predice.
 - ▷ NSP/SOP: tareas de relación entre oraciones (históricamente usadas; hoy menos críticas).
- ▶ Decoder-only (GPT):
 - ▷ Causal LM: predecir el siguiente token (entrenamiento autoregresivo).
- ▶ Encoder–Decoder (T5/BART):
 - ▷ Denoising Seq2Seq: corromper entrada (masking, permutar, eliminar spans) y reconstruir.
- ▶ Nota: todos crean representaciones ricas reutilizables para muchas tareas.

BERT



GPT






Patrones de arquitectura según tarea

- ▶ Encoder-only (BERT, RoBERTa, etc.)
 - ▷ Clasificación (sentiment, topic): usar [CLS] → capa lineal.
 - ▷ Etiquetado de secuencia (NER, PoS): proyección por token.
 - ▷ QA extractivo (SQuAD): cabezas de start/end sobre la secuencia.
- ▶ Decoder-only (GPT, etc.)
 - ▷ Generación libre/condicionada: diálogo, story, code → causal LM + muestreo.
- ▶ Encoder-Decoder (T5, BART)
 - ▷ Seq2Seq: traducción, summarization, paraphrase, style transfer.


Fine-tuning: cabezas y adaptaciones

- ▶ Heads: clasificación (softmax), regresión (MSE), marcaje por token, span prediction, LM.
- ▶ Estrategias: congelar parte de la arquitectura básica, layer-wise learning rates, early stopping.
- ▶ Parámetros eficientes (mención breve): adapters, LoRA, prompt tuning (útil cuando hay pocos datos).

BERT + sentiment analysis



GPT context learning



T5: generación de imágenes



Teddy bears swimming at the Olympics 400m Butterfly event.



A cute corgi lives in a house made out of sushi.



A cute sloth holding a small treasure chest. A bright golden glow is coming from the chest.

Métricas típicas en NLP

- ▶ Clasificación/NER: Accuracy, Precision/Recall/F1 (micro/macro), span-F1.
- ▶ QA extractivo: Exact Match (EM), F1 de tokens.
- ▶ Traducción/Resumen: BLEU, ROUGE (n-gramas; limita semántica perfecta).
- ▶ LM: Perplexity (perplejidad) como proxy de calidad del modelo.

Large Language Models (LLMs)


¿Qué son?

- ▶ Extensión de los Transformers a escalas masivas
- ▶ Modelo de lenguaje entrenado para predecir el siguiente token en un texto
- ▶ Entrenados en enormes cantidades de texto (cientos de miles de millones de tokens)
- ▶ Ejemplos: GPT-3, GPT-4, PaLM, LLaMA, etc.

GPT-3 (Brown et al., 2020)

- ▶ 175B parámetros
- ▶ 96 capas Transformer
- ▶ 96 cabezas de atención
- ▶ 300B tokens de entrenamiento
- ▶ Secuencias de hasta 2048 tokens
- ▶ Entrenado con cómputo distribuido masivo
- ▶ **Ojo (2026):** estos números ya son históricos — los modelos actuales manejan contextos de cientos de miles o millones de tokens y corpora de decenas de billones; la escala de GPT-3 hoy es la de un modelo “pequeño”

Tamaño de los LLMs (la era 2018-2022)



10

► Esta gráfica cuenta la historia *hasta* Chinchilla: crecer parámetros era la receta

¿Dónde se gasta el cómputo? (2026)

- ▶ La pregunta ya no es “¿qué tan grande el modelo?” sino **cómo repartir el presupuesto de cómputo en tres lugares:**
 1. **Preentrenamiento:** los retornos de solo escalar datos+parámetros se aplanaron
 2. **Post-entrenamiento con RL:** SFT, RLHF/DPO y RL con recompensas verificables
 3. **Cómputo en inferencia:** dejar al modelo “pensar” más tokens en los problemas difíciles
- ▶ Chinchilla (Hoffmann et al., 2022) resolvió el punto 1; los puntos 2 y 3 son la frontera actual y aún no tienen una ley limpia
- ▶ Implicación práctica: el mismo modelo puede ser rápido-y-barato o lento-y-carro según cuánto “piensa” — por eso los proveedores venden *modos* y no solo modelos

Mixture-of-Experts (MoE): la arquitectura dominante

- ▶ En 2026 casi todos los modelos de frontera son **MoE**: la capa MLP del bloque se reemplaza por muchos “expertos” y un *router*
- ▶ Por cada token se activan solo los top- k expertos (por ejemplo 2 de 64)
- ▶ Consecuencia clave: el **número total de parámetros se desacopla del costo por token**
 - ▷ un modelo de cientos de miles de millones de parámetros puede costar como uno de decenas
- ▶ Por eso las comparaciones de proveedores por “tamaño del modelo” ya no significan lo que significaban: pregunten por parámetros *activos* y costo por token, no por parámetros totales

¿Alternativas a la atención?

- ▶ El costo cuadrático de la atención en la longitud de secuencia motivó alternativas: los **modelos de espacio de estados** (Mamba y sucesores), con costo lineal
- ▶ Veredicto a 2026: **no desplazaron a los Transformers** — la atención sigue ganando en tareas de recuerdo preciso; los SSMS sobreviven en arquitecturas híbridas para contextos muy largos
- ▶ Lección de criterio: no toda alternativa prometedora reemplaza al estándar; la carga de la prueba está en el reto

Más allá del texto: modelos multimodales

- ▶ **ViT** (Vision Transformer): la imagen se corta en parches y se trata como una secuencia de tokens — el mismo Transformer de este deck, aplicado a visión
- ▶ **CLIP**: alinea imágenes y texto en un espacio común entrenando con pares (imagen, descripción) — la base de “buscar imágenes con palabras”
- ▶ Los modelos de frontera de 2026 son **nativamente multimodales**: un solo modelo lee texto, imágenes y documentos
- ▶ Para política pública esto une los dos mundos del curso: imagen satelital + texto (encuestas, registros) ya no son dos pipelines separados, son una sola entrada

¿Qué aprenden?

- ▶ Sintaxis: reglas del lenguaje
- ▶ Semántica: asociaciones de significado
- ▶ Conocimiento general: hechos del mundo
- ▶ Habilidad de completar, traducir, resumir, razonar en texto

Few-shot, Zero-shot y Prompting

► Prompting

- ▷ Interactuamos con LLMs mediante prompts (instrucciones en texto)
- ▷ Zero-shot: sin ejemplos, solo la instrucción
- ▷ Few-shot: damos algunos ejemplos de entrada-salida
- ▷ Chain-of-thought prompting: pedimos razonamiento intermedio

De LLM base a asistente

El problema del modelo base

- ▶ Un LM base solo hace una cosa: predecir el siguiente token
- ▶ Completar texto $\neq$ ser útil: puede continuar tu pregunta con más preguntas
- ▶ Tampoco tiene noción de “no sé” o “eso no lo debería contestar”
- ▶ Los asistentes que usamos (ChatGPT, Claude, Gemini) son LLMs base + **etapas adicionales de entrenamiento**

Instruction tuning (SFT)

- ▶ *Supervised fine-tuning*: seguir entrenando el modelo base con pares (instrucción, respuesta deseada) escritos/curados por humanos
- ▶ Mismo objetivo de siempre (predecir el siguiente token), datos distintos
- ▶ El modelo aprende el **formato** de ser asistente: responder, no continuar
- ▶ Pocos datos comparado con el preentrenamiento (miles vs. billones de tokens)

RLHF: aprendizaje por refuerzo con retroalimentación humana

- ▶ Problema: es fácil juzgar cuál de dos respuestas es mejor; es difícil escribir la respuesta perfecta
- ▶ Receta (InstructGPT, Ouyang et al. 2022):
 1. Humanos **comparan** pares de respuestas del modelo
 2. Con esas comparaciones se entrena un **modelo de recompensa** que predice la preferencia humana
 3. El LLM se optimiza (RL) para maximizar esa recompensa
- ▶ Variante más simple y muy usada hoy: **DPO** (Rafailov et al. 2023) — optimiza directamente sobre las comparaciones, sin modelo de recompensa
- ▶ Conexión con la semana 11: esto es *alineación como técnica*; los problemas normativos (¿preferencias de quién?) siguen abiertos

RLVR: RL con recompensas verificables

- ▶ El paso siguiente a RLHF/DPO: en dominios donde el éxito **se puede verificar mecánicamente**, no necesitas modelo de recompensa ni preferencias humanas
 - ▷ matemáticas: ¿la respuesta final es correcta?
 - ▷ código: ¿pasan los tests?
- ▶ Se entrena con RL directamente contra esa señal verificable (la receta de DeepSeek-R1, 2025)
- ▶ El modelo aprende solo a *pensar más* — cadenas largas de razonamiento — porque pensar más gana más recompensa
- ▶ Por eso el progreso 2024-2026 fue más rápido en matemáticas y código que en juicio abierto: **avanza más rápido donde hay verificador**

Modelos de razonamiento (2024-)

- ▶ Idea: gastar más cómputo **en inferencia** — el modelo genera cadenas largas de razonamiento antes de responder
- ▶ Entrenados con RL sobre problemas verificables (matemáticas, código)
- ▶ Mejoras grandes en tareas de razonamiento; costo y latencia mayores
- ▶ Moraleja del escalamiento: ya no solo “más parámetros y más datos”, también “más pensamiento por pregunta”

¿Prompt, RAG o fine-tuning?

Fine-tuning eficiente: LoRA

- ▶ Fine-tuning completo de un modelo de miles de millones de parámetros: caro y delicado
- ▶ **LoRA** (Hu et al. 2021): congela los pesos W y aprende una corrección de rango bajo $\Delta W = AB$ con A, B diminutas
- ▶ Entrena $< 1\%$ de los parámetros; rendimiento cercano al fine-tuning completo
- ▶ Combinado con cuantización (QLoRA): fine-tuning de modelos grandes en una sola GPU

RAG: generación aumentada con recuperación

- ▶ Problema: el conocimiento del LLM está congelado en sus pesos (fecha de corte, sin documentos internos, alucina fuentes)
- ▶ **RAG** (Lewis et al. 2020): antes de generar, se **buscan** los documentos relevantes (embeddings + búsqueda semántica) y se pegan al prompt
- ▶ El modelo responde *citando* el corpus: verificable y actualizable sin reentrenar
- ▶ Para gobierno es el patrón dominante: leyes, expedientes, normas — corpus que cambian y donde la trazabilidad de la fuente es obligatoria

Agentes y uso de herramientas

- ▶ Un LLM que además puede **actuar**: llamar funciones, buscar, ejecutar código, leer archivos — en un ciclo de razonar → actuar → observar (ReAct, Yao et al. 2022)
- ▶ Ojo: ReAct es el patrón *de prompting* original (2022) — la línea base conceptual; los agentes de frontera de 2026 además **entrenan la política de uso de herramientas con RL** sobre tareas completas
- ▶ El modelo decide *qué* herramienta usar y *cuándo*; el sistema alrededor decide *qué le está permitido*
- ▶ Dirigir, supervisar y auditar agentes tiene su propio deck en este curso
- ▶ Cambia la habilidad que importa: de escribir el código a **especificar y verificar** el trabajo del agente
- ▶ (Exactamente lo que practican en el proyecto final de este curso)

¿Qué opción elegir?

Necesitas...	Opción
Cambiar el formato o el tono, tarea estándar	Prompting (zero/few-shot)
Responder sobre documentos propios/cambiantes, con fuentes	RAG
Comportamiento especializado consistente, mucho volumen, datos etiquetados	Fine-tuning (LoRA)
Tareas de varios pasos con acciones	Agente + herramientas

- En la práctica se combinan; empezar siempre por lo más barato (prompting) y escalar solo si la evaluación lo justifica

Evaluación de LLMs

¿Por qué no bastan las métricas clásicas?

- ▶ BLEU/ROUGE comparan contra *una* referencia; en generación abierta hay infinitas respuestas correctas
- ▶ Perplejidad mide ajuste al corpus, no utilidad ni veracidad
- ▶ Un modelo puede tener excelente perplejidad y aún así inventar cifras con total seguridad

Benchmarks y sus trampas

- ▶ Baterías estándar (conocimiento, razonamiento, código) permiten comparar modelos...
- ▶ ...pero: **contaminación** (el test estaba en los datos de entrenamiento), saturación, y *teaching to the test*
- ▶ Regla práctica: un benchmark público mide lo que el benchmark mide, no tu caso de uso
- ▶ Respuesta del campo (2026): benchmarks que solo puntúan problemas **fechados después del corte de entrenamiento** del modelo, y evals privados donde solo se publica el agregado
- ▶ Para decisiones de despliegue: construir un conjunto de evaluación **propio**, con datos reales del problema y que el proveedor nunca haya visto

LLM-as-judge y evaluación humana

- ▶ Evaluación humana: el estándar de oro, cara y lenta
- ▶ **LLM-as-judge**: usar otro LLM para calificar respuestas contra una rúbrica
 - ▷ Escalable y barato; útil como primer filtro
 - ▷ Sesgos conocidos: prefiere respuestas largas, prefiere su propio estilo, sensible al orden
- ▶ Buena práctica: validar al juez contra una muestra calificada por humanos antes de confiar en él

Alucinaciones, calibración y red-teaming

- ▶ **Alucinación:** afirmación fluida y falsa; se mide con conjuntos de verificación factual y tasa de citas correctas (crítico en RAG)
- ▶ **Calibración:** ¿la confianza expresada corresponde a la tasa de acierto? (el ECE que calcularon en la tarea de regularización, ahora sobre texto)
- ▶ **Red-teaming:** buscar activamente cómo hacer fallar al modelo (jailbreaks, sesgos, fugas de datos) *antes* que los usuarios lo hagan

Evaluación para despliegue público

- ▶ Si una agencia va a desplegar un LLM, el mínimo exigible:
 1. Conjunto de evaluación propio y fuera del alcance del proveedor
 2. Métricas **por subgrupo** (¿funciona igual para todos los ciudadanos?)
 3. Tasa de alucinación / citas verificables si informa decisiones
 4. Monitoreo continuo post-despliegue (los modelos y los datos cambian)
 5. Ruta de escalamiento a un humano y responsabilidad clara
- ▶ “Salió bien en el benchmark” no es una evaluación de despliegue

Transformers y políticas públicas

Texto legislativo y legal

- ▶ Clasificación multi-etiqueta de legislación de la UE con BERT y variantes (Chalkidis et al. 2019)
- ▶ Predicción de votos nominales desde el texto de las iniciativas (Korn & Newman 2020)
- ▶ Revisión de documentos legales a escala (Wei et al. 2019)
- ▶ Todo lo que vimos hoy (tokenización → embeddings → atención → fine-tuning) es exactamente el pipeline de estos papers

LLMs como herramienta de investigación social

- ▶ Gilardi, Alizadeh & Kubli (2023, *PNAS*): ChatGPT supera a anotadores de crowdsourcing en tareas de clasificación de texto político — cambia la economía de etiquetar datos
- ▶ Ziems et al. (2024, *Computational Linguistics*): ¿pueden los LLMs transformar la ciencia social computacional? — panorama de usos y límites
- ▶ Dell (2025, *Journal of Economic Literature*): *Deep Learning for Economists* — guía de estas herramientas para investigación económica aplicada
- ▶ Patrón común: el LLM como **instrumento de medición** — y entonces su sesgo es sesgo de medición: hay que validarlo como cualquier instrumento

Cierre del curso técnico

- ▶ De regresión lineal a LLMs, el esqueleto no cambió: modelo flexible + pérdida derivada de un supuesto probabilístico + SGD sobre minibatches
- ▶ Lo que sí cambió: la escala, y con ella *emergen* capacidades que nadie programó
- ▶ Ustedes no van a implementar un Transformer en el trabajo; van a **decidir** si se usa, **especificar** qué debe hacer y **verificar** que lo haga
- ▶ Ese criterio — saber qué pedir y saber qué puede salir mal — es lo que este curso intentó construir
- ▶ Semana 11: por qué funciona (nadie sabe del todo) y qué implica para la sociedad